

Laboratório de Ciência de Dados: Análise de classificação textual no dataset ASSIN

Rian Albano Sousa Ribeiro, 57389
Lincoln Alyson de Melo Lembi, 557460

**Itapajé
2025**

1. Introdução

Este relatório apresenta a análise dos resultados de um experimento de classificação de pares de sentenças do dataset ASSIN, cujo objetivo é avaliar o desempenho de modelos clássicos de aprendizado de máquina em uma tarefa de inferência textual em português. O estudo busca comparar diferentes representações textuais e classificadores, explorando como técnicas tradicionais de processamento de linguagem natural se comportam em uma tarefa de natureza semântica, como identificação de relações entre sentenças. Ao longo do trabalho, são descritos os procedimentos adotados, a análise exploratória dos dados e a avaliação quantitativa dos modelos, culminando em uma discussão crítica sobre os resultados alcançados.

2. Metodologia

O dataset utilizado foi obtido por meio da biblioteca Hugging Face, que disponibiliza uma versão pública e padronizada do conjunto de dados ASSIN. O conjunto contém pares de sentenças em português associados a rótulos que indicam a relação semântica entre elas. Para os experimentos realizados, utilizou-se o subconjunto de treinamento, que foi posteriormente dividido em conjuntos de treino e teste na proporção de 80% e 20%, de forma estratificada, garantindo a preservação da distribuição das classes.

Antes do treinamento dos modelos, os textos foram submetidos a uma série de etapas de pré-processamento com o intuito de reduzir ruído e padronizar a representação do conteúdo textual. Esse processo incluiu a conversão para letras minúsculas, remoção de acentuação, eliminação de caracteres especiais, números e URLs, além da retirada de palavras muito frequentes da língua portuguesa que não contribuem significativamente para o significado das sentenças. Após essa etapa, cada par de sentenças foi concatenado em uma única sequência de texto, permitindo que os algoritmos considerassem as informações das duas sentenças simultaneamente.

O dataset ASSIN contém três classes distintas, associadas à relação semântica entre cada par de sentenças:

As sentenças não apresentam inferência lógica entre si, podendo tratar de assuntos diferentes ou contradizer parcialmente uma à outra.

As sentenças tratam de temas relacionados e compartilham elementos semânticos, mas não são equivalentes.

As sentenças transmitem essencialmente a mesma informação, sendo consideradas paráfrases ou equivalentes.

Essas classes foram utilizadas como rótulos para o processo de classificação supervisionada.



Figura 2 - Nuvem de palavras




Figura 3 - Gráfico de tokens

Na fase de extração de características, foram empregadas duas abordagens diferentes: a Bag-of-Words tradicional e a ponderação por frequência inversa de documentos (TF-IDF). Em ambas as abordagens, utilizou-se a representação por uni-gramas e bi-gramas, limitando-se o vocabulário a um número máximo de termos mais informativos, com o objetivo de reduzir dimensionalidade e ruído.

Em relação aos classificadores, foram avaliados três modelos amplamente utilizados em tarefas de classificação textual: Naive Bayes, Regressão Logística e Máquinas de Vetores de Suporte (SVM) com kernel linear. Para minimizar os efeitos do desbalanceamento entre classes, foram utilizados pesos adaptativos durante o treinamento, além de um experimento complementar com reamostragem por

oversampling, cujo propósito foi verificar o comportamento dos modelos quando as classes minoritárias possuem maior representatividade.

2.1 Análise exploratória dos dados

A análise inicial revelou que o dataset apresenta um certo grau de desbalanceamento entre as classes, com algumas categorias ocorrendo com maior frequência do que outras. Essa característica é particularmente relevante, pois pode influenciar o desempenho dos modelos, favorecendo previsões voltadas às classes majoritárias.

A distribuição do tamanho das sentenças mostrou que a maioria dos pares possui uma quantidade relativamente pequena de palavras, o que indica que os modelos trabalham predominantemente com frases curtas. Esse fator pode dificultar a identificação de relações semânticas mais sutis, uma vez que há menos contexto disponível para inferência.

A análise da frequência dos termos revelou a presença recorrente de palavras associadas a contextos descritivos e informativos, o que reflete a natureza do corpus. A remoção de stopwords contribuiu para destacar termos mais relevantes, proporcionando uma representação mais informativa para os classificadores. A nuvem de palavras e a lista dos termos mais frequentes também evidenciaram temas circulantes no conjunto de dados, como entidades, ações e qualificadores.

3. Resultados e discussão

Os experimentos realizados evidenciaram que o conjunto de dados apresenta forte desbalanceamento entre as classes, com predominância expressiva da classe 0, seguida pela classe 1 e, por fim, pela classe 2 como a classe mais rara. Esse fator impactou diretamente o desempenho geral dos classificadores, que demonstraram elevada capacidade para reconhecer a classe majoritária, porém dificuldades significativas para identificar corretamente as classes minoritárias.

A avaliação dos modelos com a representação Bag-of-Words indicou desempenhos bastante semelhantes entre os classificadores. O Naive Bayes com CountVectorizer apresentou acurácia de 65,0% e F1 ponderado de 0,63, enquanto a Regressão Logística e o SVM obtiveram resultados ligeiramente inferiores ou equivalentes, com F1 médio em torno de 0,62. Em todos esses modelos, observou-se alta taxa de acerto na classe 0, com valores de revocação superiores a 79%, mas desempenho consideravelmente inferior nas classes 1 e 2, evidenciando a dificuldade em modelar padrões mais sutis de relação semântica.

Ao empregar a representação TF-IDF, esperava-se melhora significativa no desempenho geral. No entanto, apenas o SVM apresentou ganho real com essa abordagem, atingindo o melhor resultado global entre todos os modelos testados, com F1 ponderado de 0,633 e acurácia de 65,3%. Esse resultado indica que a ponderação por frequência inversa dos termos auxilia o SVM a construir fronteiras de decisão mais eficientes, reduzindo a influência de termos excessivamente frequentes e destacando palavras mais discriminativas.

Por outro lado, o Naive Bayes combinado com TF-IDF apresentou um comportamento inadequado, apesar de alcançar a maior acurácia global (73,2%). A análise da matriz de confusão e do relatório de classificação revelou que esse valor elevado de acurácia ocorreu devido à previsão quase exclusiva da classe majoritária. O modelo praticamente ignorou as demais classes, atingindo revocação nula ou próxima de zero nas classes 1 e 2. Esse comportamento caracteriza um modelo enviesado e inadequado para aplicações reais, pois falha completamente em capturar a diversidade do problema.

A Regressão Logística com TF-IDF demonstrou desempenho inferior em comparação à sua versão com Bag-of-Words, o que sugere que a representação TF-IDF, isoladamente, não garantiu melhor separabilidade no espaço vetorial para esse modelo específico. O F1 ponderado obtido foi de aproximadamente 0,616, sendo impactado principalmente pela baixa precisão e revocação nas classes minoritárias.

O experimento complementar com oversampling aplicado à Regressão Logística apresentou melhora perceptível na revocação da classe menos

representada, que passou a ser reconhecida com maior frequência em comparação às abordagens anteriores. Entretanto, esse ganho ocorreu às custas da redução da acurácia total, que caiu para 62,1%. Isso indica que o oversampling contribuiu para reduzir o viés do modelo em favor da classe majoritária, mas também aumentou a taxa de falsos positivos, gerando confusões entre as classes.

De forma geral, todos os modelos apresentaram dificuldades consideráveis em distinguir especialmente a classe 2, cuja taxa de acerto permaneceu baixa em todos os cenários, inclusive após a aplicação de técnicas de balanceamento. Esse comportamento demonstra a complexidade semântica da tarefa de inferência textual, na qual classes semanticamente próximas demandam capacidade de compreensão além da simples coincidência lexical.

Abaixo, pode-se observar as matrizes de confusão e as métricas de cada classificador e suas combinações.




Figura 4 - Matriz de confusão Naive Bayes

	precision	recall	f1-score	support
0	0.76	0.79	0.77	731
1	0.29	0.27	0.28	210
2	0.10	0.07	0.08	59
accuracy			0.64	1000
macro avg	0.38	0.38	0.38	1000
weighted avg	0.62	0.64	0.63	1000

Figura 5 - Métricas com Naive Bayes




Figura 6 - Matriz de confusão Regressão Logística

	precision	recall	f1-score	support
0	0.75	0.81	0.78	731
1	0.30	0.26	0.27	210
2	0.12	0.05	0.07	59
accuracy			0.65	1000
macro avg	0.39	0.37	0.37	1000
weighted avg	0.62	0.65	0.63	1000

Figura 7 - Métricas Regressão Logística




Figura 8 - Matriz de confusão SVM

	precision	recall	f1-score	support
0	0.76	0.80	0.78	731
1	0.27	0.26	0.26	210
2	0.07	0.03	0.04	59
accuracy			0.64	1000
macro avg	0.36	0.36	0.36	1000
weighted avg	0.61	0.64	0.63	1000

Figura 9 - Métricas SVM




Figura 10 - Matriz de confusão Naive Bayes com TD-IDF

	precision	recall	f1-score	support
0	0.73	1.00	0.85	731
1	1.00	0.00	0.01	210
2	0.00	0.00	0.00	59
accuracy			0.73	1000
macro avg	0.58	0.33	0.28	1000
weighted avg	0.74	0.73	0.62	1000

Figura 11 - Métricas Naive Bayes com TF-IDF




Figura 12 - Matriz de confusão Regressão Logística com TF-IDF

	precision	recall	f1-score	support
0	0.77	0.71	0.74	731
1	0.30	0.36	0.33	210
2	0.11	0.14	0.12	59
accuracy			0.60	1000
macro avg	0.39	0.40	0.40	1000
weighted avg	0.63	0.60	0.62	1000

Figura 13 - Métricas Regressão Logística com TF-IDF




Figura 14 - Matriz de confusão SVM com TF-IDF

	precision	recall	f1-score	support
0	0.76	0.75	0.76	731
1	0.30	0.30	0.30	210
2	0.12	0.14	0.12	59
accuracy			0.62	1000
macro avg	0.39	0.40	0.40	1000
weighted avg	0.63	0.62	0.62	1000

Figura 15 - Métricas SVM com TF-IDF




Figura 16 - Matriz de confusão Regressão Logística com TF-IDF Oversampled

	precision	recall	f1-score	support
0	0.76	0.75	0.76	731
1	0.30	0.30	0.30	210
2	0.12	0.14	0.12	59
accuracy			0.62	1000
macro avg	0.39	0.40	0.40	1000
weighted avg	0.63	0.62	0.62	1000

Figura 17 - Métricas Regressão Logística com TF-IDF Oversampled

4. Conclusão

Os resultados obtidos demonstram que, dentro das abordagens clássicas de aprendizado de máquina testadas, o modelo SVM com representação TF-IDF apresentou o melhor desempenho geral, equilibrando a capacidade de classificação das diferentes classes e alcançando a maior pontuação F1 ponderada entre todos os experimentos. Ainda assim, mesmo o melhor modelo apresentou limitações relevantes, principalmente no reconhecimento das classes minoritárias.

A análise evidencia que altos valores de acurácia, como observado no Naive Bayes com TF-IDF, não garantem qualidade real quando há forte desbalanceamento nos dados. O fato desse modelo praticamente ignorar duas das três classes expõe a necessidade de métricas mais informativas, como F1 por classe e médias macro, para avaliação mais justa.

Apesar de o oversampling ter melhorado parcialmente a identificação das classes menos frequentes, a redução da acurácia global mostra que o balanceamento artificial não soluciona completamente o problema e deve ser aplicado com cautela. Esses resultados sugerem que, embora técnicas tradicionais ofereçam uma base sólida de comparação, elas possuem limitações claras quando aplicadas a tarefas de inferência semântica.

Conclui-se, portanto, que os modelos tradicionais são adequados como baseline, mas insuficientes para representar complexidades linguísticas profundas. Para alcançar melhores resultados em tarefas como a ASSIN, é necessário recorrer

a modelos baseados em representações contextualizadas, como redes neurais com embeddings semânticos profundos, que são capazes de capturar relações mais abstratas entre sentenças.

Link para os códigos:

<https://colab.research.google.com/drive/1tOscKUrIXz-kyka6f5LJvnLCmMTpln9T?usp=sharing> .