




Laboratório de Ciência de Dados

ANÁLISE DE CLASIFICASSÃO TEXTUAL NO DATASET ASSIN



Rian Albano e Lincoln Alyson





INTRODUÇÃO


Vamos discutir a análise dos resultados de um experimento de classificação de pares de sentenças do dataset ASSIN, cujo objetivo é avaliar o desempenho de modelos clássicos de aprendizado de máquina em uma tarefa de inferência textual em português. O estudo busca comparar diferentes representações textuais e classificadores, explorando como técnicas tradicionais de processamento de linguagem natural se comportam em uma tarefa de natureza semântica, como identificação de relações entre sentenças.






METODOLOGIA

Antes do treinamento dos modelos, os textos foram submetidos a uma série de etapas de pré-processamento com o intuito de reduzir ruído e padronizar a representação do conteúdo textual. Esse processo incluiu a conversão para letras minúsculas, remoção de acentuação, eliminação de caracteres especiais, números e URLs, além da retirada de palavras muito frequentes da língua portuguesa que não contribuem significativamente para o significado das sentenças. Após essa etapa, cada par de sentenças foi concatenado em uma única sequência de texto, permitindo que os algoritmos considerassem as informações das duas sentenças simultaneamente.



LSRT_meta_tags

```
<!-- <link href="https://fonts.googleapis.com/css?family=Open+Sans" rel="stylesheet" type="text/css">
<link href="https://cdnjs.cloudflare.com/ajax/libs/bootstrap-datepicker/1.7.0/css/datepicker.min.css" rel="stylesheet" type="text/css">
<link href="https://unpkg.com/leaflet@1.0.1/dist/leaflet.css" rel="stylesheet" type="text/css">
<link href="https://gitcdn.github.io/bootstrap-toggle/2.2.2/css/bootstrap-toggle.min.css" rel="stylesheet" type="text/css">
<link href="https://cdnjs.cloudflare.com/ajax/libs/leaflet.js" rel="stylesheet" type="text/css">
```








METODOLOGIA

Na fase de extração de características, foram empregadas duas abordagens diferentes: a Bag-of-Words tradicional e a ponderação por frequência inversa de documentos (TF-IDF). Em ambas as abordagens, utilizou-se a representação por uni-gramas e bi-gramas, limitando-se o vocabulário a um número máximo de termos mais informativos, com o objetivo de reduzir dimensionalidade e ruído.

Em relação aos classificadores, foram avaliados três modelos amplamente utilizados em tarefas de classificação textual: Naive Bayes, Regressão Logística e Máquinas de Vetores de Suporte (SVM) com kernel linear.




ANÁLISE EXPLORATÓRIA **DOS DADOS**



A análise inicial revelou que o dataset apresenta um certo grau de desbalanceamento entre as classes, com algumas categorias ocorrendo com maior frequência do que outras. Essa característica é particularmente relevante, pois pode influenciar o desempenho dos modelos, favorecendo previsões voltadas às classes majoritárias.



A distribuição do tamanho das sentenças mostrou que a maioria dos pares possui uma quantidade relativamente pequena de palavras, o que indica que os modelos trabalham predominantemente com frases curtas. Esse fator pode dificultar a identificação de relações semânticas mais sutis, uma vez que há menos contexto disponível para inferência.

A análise da frequência dos termos revelou a presença recorrente de palavras associadas a contextos descritivos e informativos, o que reflete a natureza do corpus. A remoção de stopwords contribuiu para destacar termos mais relevantes, proporcionando uma representação mais informativa para os classificadores.





ANÁLISE EXPLORATÓRIA DOS DADOS



RESULTADOS & DISCUSSÕES



Os experimentos mostraram que o dataset apresenta forte desbalanceamento entre as classes, o que impactou diretamente o desempenho dos classificadores. Todos os modelos tiveram desempenho elevado na classe majoritária, mas apresentaram grande dificuldade em reconhecer corretamente as classes menos frequentes.

Entre as abordagens testadas, o SVM com representação TF-IDF obteve o melhor desempenho global, alcançando a maior pontuação F1 ponderada. Isso indica que a combinação de vetores ponderados com fronteiras lineares de decisão foi a mais eficiente para esse problema.





RESULTADOS & DISCUSSÕES



	precision	recall	f1-score	support
0	0.76	0.75	0.76	731
1	0.30	0.30	0.30	210
2	0.12	0.14	0.12	59
accuracy			0.62	1000
macro avg	0.39	0.40	0.40	1000
weighted avg	0.63	0.62	0.62	1000





COMPARAÇÃO ENTRE OS MODELOS

A representação Bag-of-Words produziu resultados relativamente consistentes entre os modelos, mas a aplicação do TF-IDF mostrou efeitos distintos. Enquanto o SVM se beneficiou dessa técnica, apresentando melhora no desempenho, a Regressão Logística não obteve ganhos significativos.

O Naive Bayes com TF-IDF apresentou alta acurácia, porém esse valor foi artificial, pois o modelo classificou quase todos os exemplos como pertencentes à classe majoritária. Isso mostra que a acurácia isolada pode ser enganosa em contextos com desbalanceamento.




ANÁLISE DOS ERROS

As maiores taxas de erro ocorreram nas classes minoritárias, especialmente na classe mais rara do conjunto. Mesmo com técnicas de balanceamento, o desempenho nessas classes permaneceu limitado.

A análise das matrizes de confusão mostrou que os modelos frequentemente confundem classes semanticamente próximas, o que evidencia a dificuldade dos métodos tradicionais em capturar nuances de significado e relações inferenciais entre sentenças.




CONCLUSÃO



O SVM com TF-IDF foi o modelo mais eficaz entre os avaliados, funcionando como um baseline sólido para experimentos com inferência textual em português. No entanto, todos os modelos apresentaram limitações importantes, principalmente na identificação de relações mais sutis entre sentenças e no reconhecimento das classes menos representadas.

Os resultados mostram que embora modelos tradicionais sejam úteis como ponto de partida, eles não são suficientes para resolver completamente tarefas de inferência semântica.

Para avanços significativos, recomenda-se a adoção de modelos baseados em representações contextualizadas, como redes neurais profundas, que possuem maior capacidade de compreensão semântica.





OBRIGADO
PELA ATENÇÃO

