Mini-projeto completo de NLP

RAMON JORDAO GOMES BARROSO e ELYSON CAIQUE ALVES BRITO

Questão 1 – Pré-processamento e limpeza textual

1.1 Dados e auditoria

Foi utilizada a configuração ptbr do corpus ASSIN, com 2500 pares no treino, 500 na validação e 2000 no teste. Cada par tem uma premissa e uma hipótese em português brasileiro, um relatedness_score (similaridade, de 1 a 5) e um rótulo entailment_judgment: 0 = none, 1 = entailment e 2 = paraphrase, conforme a documentação do corpus no Hugging Face. O sentence_pair_id é apenas um identificador e o relatedness_score não é usado como entrada do classificador, pois é uma anotação humana fortemente associada ao rótulo.

Antes de limpar, os dados foram auditados para que cada etapa fosse justificada por evidência:

- não há valores nulos, textos vazios nem pares duplicados, e nenhum par de validação ou teste aparece no treino;
- as frases são curtas (média de 13 palavras, máximo de 25);
- não há URLs, HTML, menções, hashtags nem caracteres corrompidos;
- há ruído tipográfico leve: aspas curvas (61 frases no treino), travessões (11) e espaços duplos (2);
- há muitos números, R$ e % (1805, 210 e 232 frases no treino), que costumam ser decisivos para a relação entre as frases;
- cerca de 7% a 10% das frases contêm palavras de negação, em todas as classes.

1.2 Etapas aplicadas e justificativas

- **Normalização.** Normalização Unicode (NFC), padronização de aspas e travessões, colapso de espaços e conversão para minúsculas. Essas operações não alteram o significado. O texto é passado ao analisador com as maiúsculas originais, para que nomes próprios e lemas sejam reconhecidos corretamente, e só depois convertido para minúsculas. Acentos, números, R$ e % foram mantidos.
- **Remoção de ruído.** Apenas a pontuação foi removida na etapa de tokens. Como a auditoria não encontrou URLs, HTML nem menções, não foram aplicadas remoções para esses padrões.

- **Tokenização.** Realizada com o modelo pt_core_news_sm do spaCy, que trata melhor casos como R$ 3,8, palavras com hífen e abreviações do que a separação simples por espaços.
- **Lematização.** Escolhida em vez de stemming porque produz palavras reais e legíveis, reduzindo o vocabulário sem truncar os termos. O vocabulário do treino passou de 10029 tokens distintos para 7812 lemas.
- **Stopwords.** Foi gerada uma versão sem stopwords (7595 lemas distintos; 35639 palavras no total, contra 64800 tokens), mas com uma lista de 39 palavras protegidas que nunca são removidas: negações (não, nunca, sem, nem, nenhum…), quantificadores (mais, menos, muito, pouco, todo…) e palavras de restrição ou contraste (apenas, somente, mas, porém, ainda, já…). Remover a negação tornaria uma premissa e sua negação artificialmente parecidas, o que prejudicaria a tarefa. As versões com e sem stopwords foram mantidas separadas, para comparar seu efeito nos classificadores.
- **Premissa e hipótese.** Foram processadas separadamente, com as mesmas regras, preservando sua ordem.

Os arquivos originais foram preservados. Os dados processados mantêm as colunas originais e acrescentam, para cada texto, as versões normalizada, em tokens, em lemas e em lemas sem stopwords.

1.3 Desbalanceamento

No treino, a classe 0 tem 1947 exemplos (77,9%), a classe 1 tem 437 (17,5%) e a classe 2 tem 116 (4,6%); validação e teste têm proporções semelhantes. Por isso a acurácia isolada seria enganosa, e serão usadas métricas por classe (precision, recall e F1, incluindo o F1 macro). Foram preparadas duas alternativas, ambas calculadas somente a partir do treino:

- pesos de classe, proporcionais ao inverso da frequência (0,428; 1,907; 7,184);
- oversampling aleatório das classes minoritárias até 1947 exemplos cada, com semente fixa.

A validação e o teste não foram alterados, para refletir a distribuição real. O oversampling duplica exemplos da classe 2 cerca de 17 vezes, o que pode levar o modelo a memorizá-los; por isso as duas estratégias foram comparadas na validação, e não combinadas, antes de decidir qual usar.

1.4 Verificação

Um script de verificação confere, nos três conjuntos, que o número de linhas, os identificadores, os rótulos, as pontuações de similaridade e os textos originais permanecem inalterados; que não há valores nulos nem textos vazios nas versões processadas; que a normalização removeu aspas curvas, travessões e espaços

duplicados; e que todas as palavras protegidas, incluindo as negações, sobrevivem à remoção de stopwords. Também foram inspecionados exemplos antes e depois do processamento.

1.5 Limitações

O lematizador do modelo pequeno do spaCy pode errar em palavras raras, e trechos em inglês (como títulos de álbuns) não recebem tratamento específico. A lista de palavras protegidas é uma decisão do grupo e pode ser ajustada conforme os resultados dos classificadores.

Questão 2 – Análise exploratória do corpus

A análise usa os dados processados na Questão 1. As estatísticas de tamanho e de distribuição de classes cobrem os três conjuntos; as análises de palavras e as representações numéricas usam apenas o treino, para não consultar validação e teste. Os rótulos e o relatedness_score servem só para colorir gráficos e avaliar resultados, e nenhum modelo é treinado com eles nesta questão.

2.1 Tamanho do corpus e número de classes

O corpus tem 5000 pares de frases (2500 no treino, 500 na validação e 2000 no teste), 130184 tokens e 14497 palavras distintas. O problema tem três classes: none (0), entailment (1) e paraphrase (2).

Conjunto	Pares	Tokens	Vocabulário	Lemas distintos	Aparecem 1 vez
Treino	2500	64800	10029	7812	4368
Validação	500	12848	3543	2947	1811
Teste	2000	52536	8646	6786	3853
Total	5000	130184	14497	11202	5981

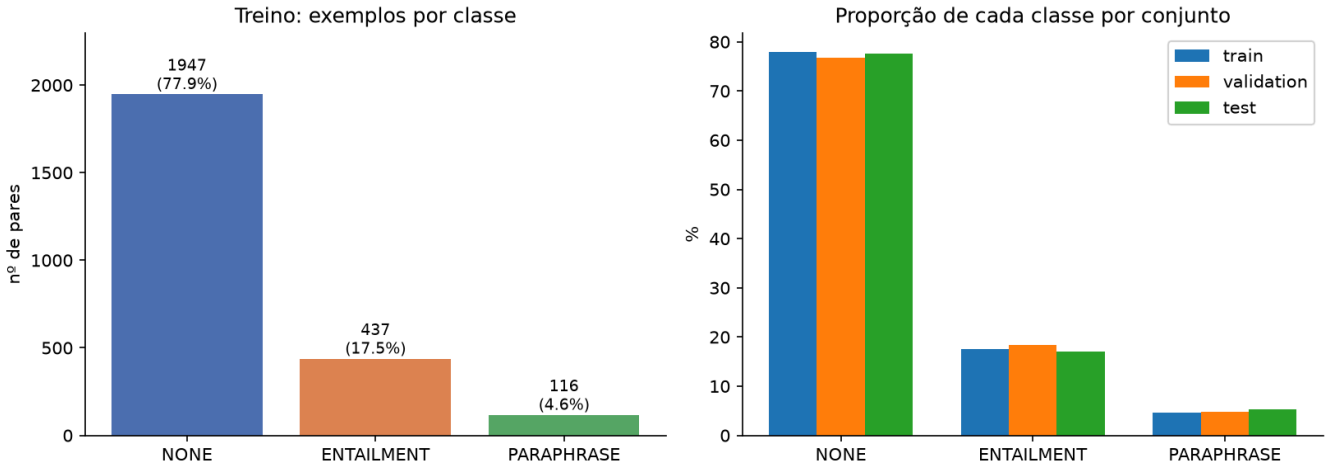
As premissas têm em média 14,0 tokens e as hipóteses, 12,0. No treino, as premissas de entailment são mais longas (15,6 tokens) que suas hipóteses (11,3), enquanto em paraphrase os dois tamanhos são quase iguais (13,4 e 13,3).

2.2 Distribuição de classes

Classe	Treino n	Treino %	Validação n	Validação %	Teste n	Teste %
0 – none	1947	77,9	384	76,8	1553	77,6
1 – entailment	437	17,5	92	18,4	341	17,0

Classe	Treino n	Treino %	Validação n	Validação %	Teste n	Teste %
2 – paraphrase	116	4,6	24	4,8	106	5,3

As classes são fortemente desbalanceadas: no treino, a maior classe tem 16,8 vezes mais exemplos que a menor, e a proporção é parecida nos três conjuntos. Por isso a acurácia isolada seria enganosa e as classes minoritárias exigem atenção nas etapas seguintes. O relatedness_score cresce com a classe (média de 2,74 em none, 3,97 em entailment e 4,88 em paraphrase), com faixas de valores quase disjuntas: de 1 a 4,5, de 3 a 5 e de 4 a 5, respectivamente.

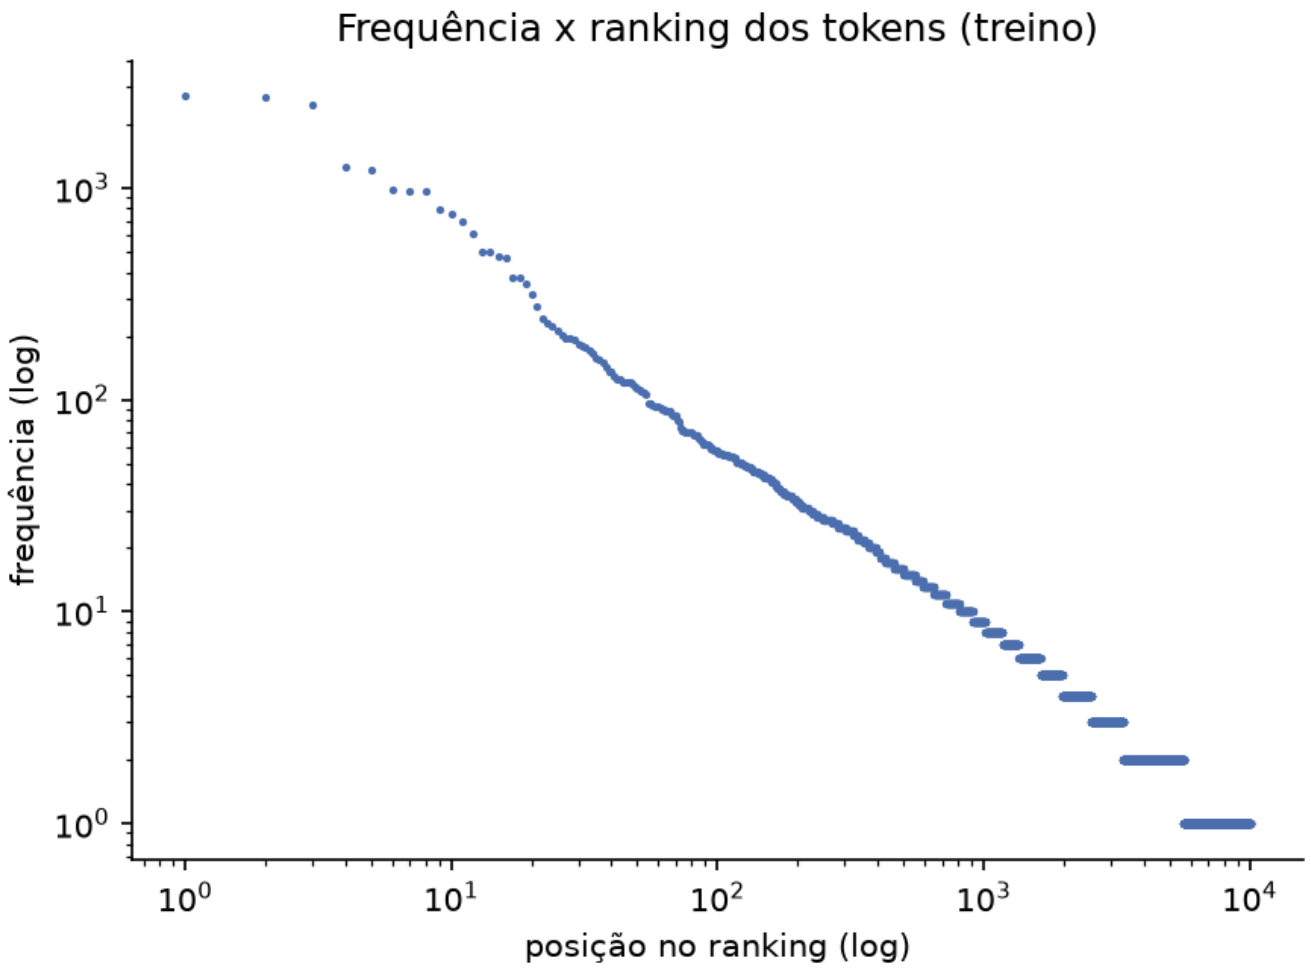


2.3 Frequência de palavras

As análises desta seção usam lemas sem stopwords, exceto nos casos indicados. As palavras mais frequentes do treino são não (378 ocorrências), ano (339), mais (243), já (203), ainda e dia (159 cada). Várias delas são palavras funcionais que foram protegidas na Questão 1 (negação, quantificação e contraste), o que mostra que essa proteção preserva termos de alta frequência. As palavras mais frequentes são semelhantes nas três classes.

As palavras mais distintivas de cada classe (razão de frequências relativas, só para palavras com pelo menos 10 ocorrências) são, em sua maioria, ligadas a assuntos específicos (google, superávit e treinador em none; cumprir, terça e cemitério em entailment; pesquisa, doação e líquido em paraphrase) e não indicam um vocabulário próprio de cada relação. As nuvens de palavras mostram o mesmo padrão: o vocabulário é de textos jornalísticos, com política, esporte e economia, e quase não varia entre as classes.

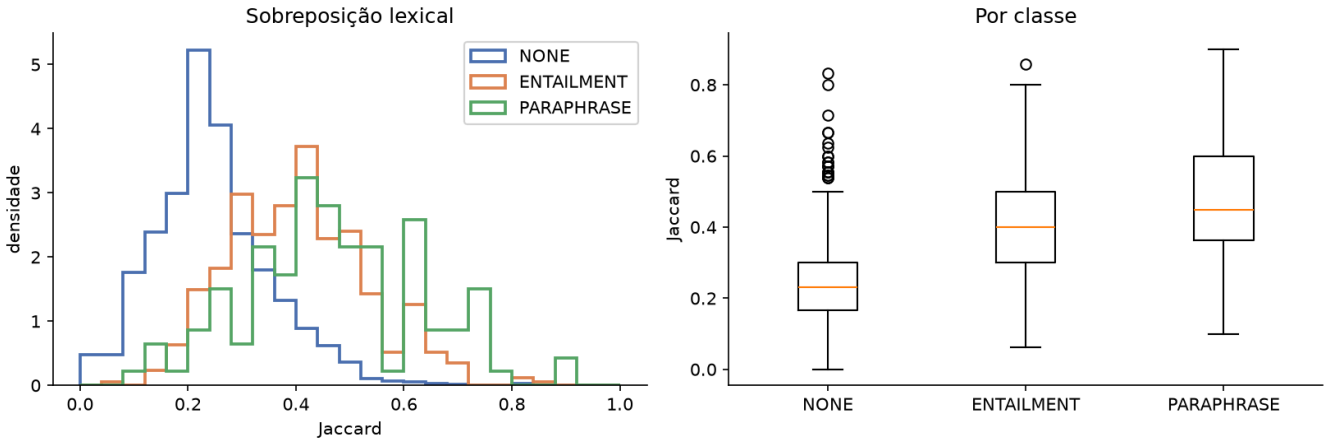
A distribuição de frequências segue aproximadamente a lei de Zipf (Figura 2): a inclinação da reta em escala logarítmica, nas 1000 primeiras posições, é −0,88. Das 10029 palavras do treino, 4368 (43,6%) aparecem uma única vez, e as 10 mais frequentes cobrem 22,9% dos tokens. Essa cauda longa de palavras raras indica um vocabulário esparso para um corpus de 2500 pares.



2.4 Negação e sobreposição lexical

Duas características se diferenciam entre as classes. A primeira é a negação: nos pares none, 14,5% têm negação em apenas uma das frases, contra 5,0% em entailment e 5,1% em paraphrase. A segunda é a sobreposição de palavras entre premissa e hipótese, medida pelo índice de Jaccard: média de 0,24 em none, 0,40 em entailment e 0,47 em paraphrase (Figura 3). As distribuições se sobrepõem bastante, de modo que a sobreposição lexical ajuda, mas não basta para decidir a classe.

Classe	Em nenhuma (%)	Nas duas (%)	Só na premissa (%)	Só na hipótese (%)
none	83,7	1,8	8,0	6,5
entailment	89,2	5,7	3,4	1,6
paraphrase	87,9	6,9	1,7	3,4



2.5 Conversão para dataset numérico

O corpus foi convertido em duas representações numéricas, ambas ajustadas somente no treino e aplicadas à validação e ao teste:

- **TF-IDF do par:** matriz esparsa com o texto da premissa e da hipótese (lemas sem stopwords), 3367 termos (palavras com ao menos 2 ocorrências no treino) e peso 1 + log(tf). Apenas 0,28% das células são diferentes de zero.
- **Atributos de relação (13 colunas):** cosseno TF-IDF entre premissa e hipótese, índice de Jaccard, proporção da hipótese contida na premissa e vice-versa, número de lemas de cada frase, diferença de tamanho, contagem de negações em cada frase, indicador de negação assimétrica, quantidade de números em cada frase e indicador de números iguais.

O relatedness_score, o identificador e o rótulo ficam em arquivos separados e não entram nas matrizes.

2.6 Aplicações de aprendizado não supervisionado

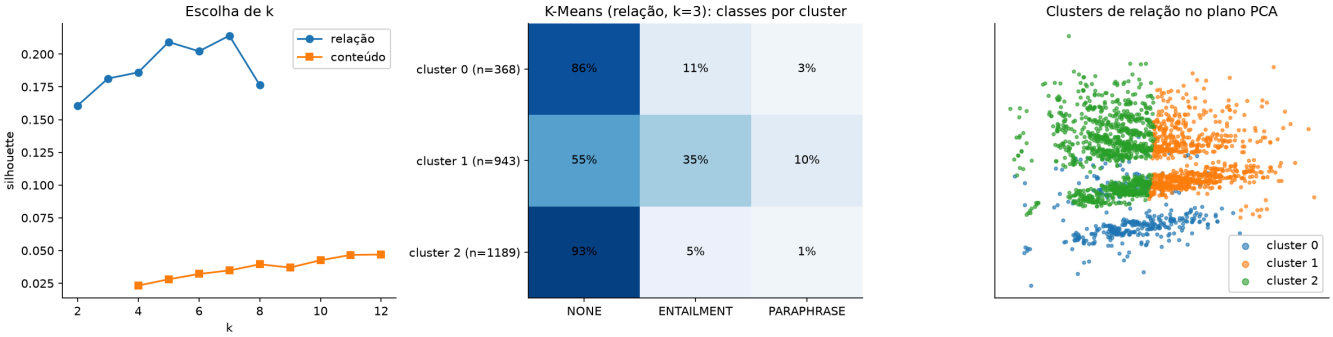
Foram exploradas cinco aplicações sobre o treino. Em todas, os rótulos servem apenas para interpretar os resultados.

1. Redução de dimensionalidade e visualização. Com SVD truncado, 2 componentes do TF-IDF explicam apenas 0,9% da variância (4,1% com 10, 13,0% com 50 e 20,8% com 100), o que mostra que o texto é de alta dimensão e pouco redundante. Já nos atributos de relação, o PCA concentra 27,8% e 18,9% da variância nos dois primeiros componentes: o primeiro agrupa as medidas de sobreposição (Jaccard, contenção e cosseno) e o segundo, as relacionadas a números e negação. A Figura 4 mostra que as classes ficam misturadas em todas as projeções. O silhouette dos rótulos é −0,12 no SVD do TF-IDF, +0,10 no PCA e −0,08 no t-SNE dos atributos de relação, ou seja, os atributos de relação separam um pouco mais, mas sem formar grupos nítidos.

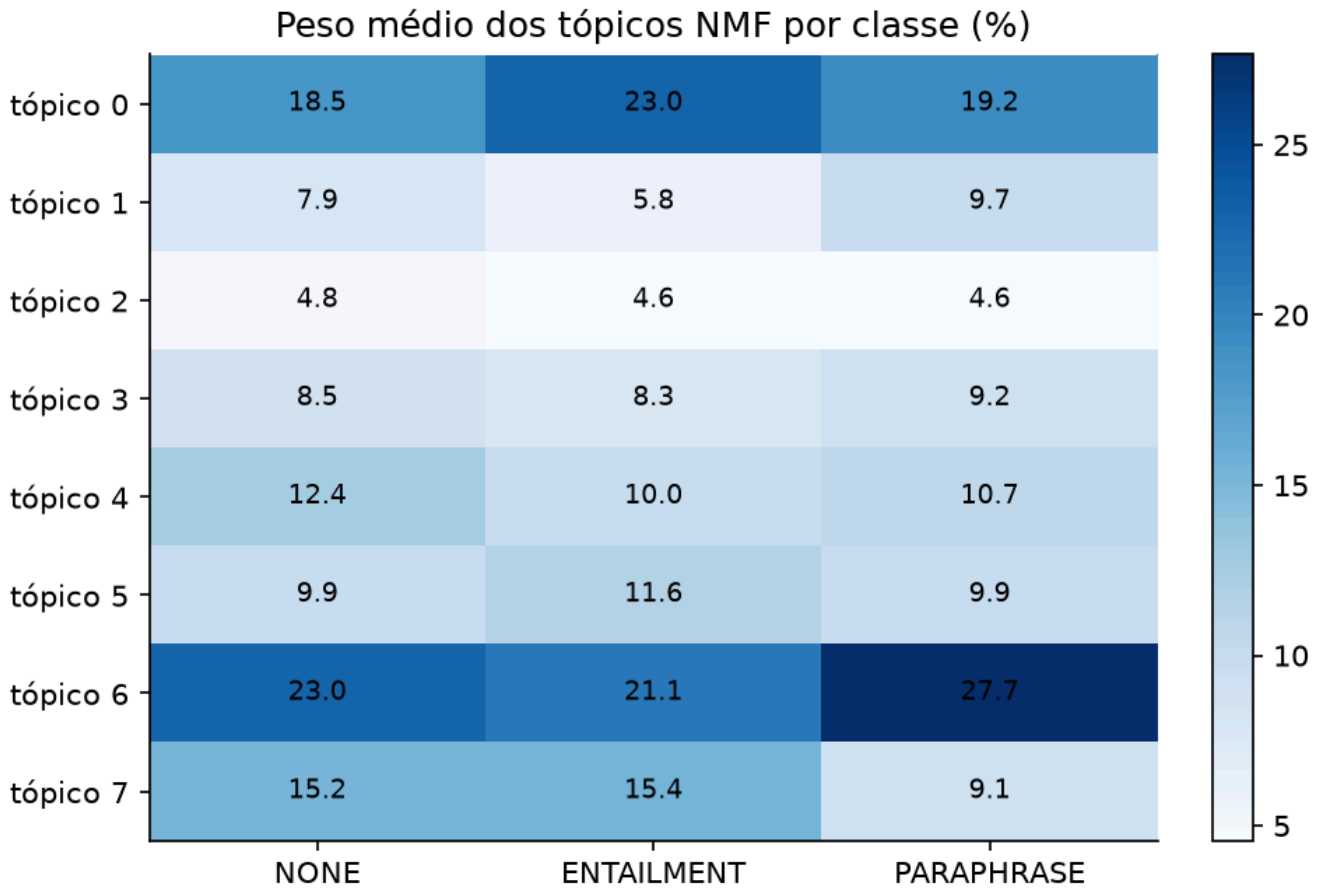


2. Agrupamento (K-Means). Aplicado aos atributos de relação padronizados, o melhor k pelo silhouette é 7 (0,214), mas com k = 3 (0,181) a comparação com as três classes é direta. Os clusters têm perfis interpretáveis: o cluster 0 é o dos pares com negação assimétrica (83% dos seus pares); o cluster 1 tem alta sobreposição lexical (Jaccard médio de 0,40) e reúne cerca de 76% dos pares de entailment e 79% dos de paraphrase; o cluster 2 tem baixa sobreposição e é quase todo none. A concordância com as classes é baixa (ARI = 0,10; NMI = 0,11), pois o agrupamento só capta relações lexicais. Aplicado ao conteúdo (TF-IDF reduzido por SVD), o silhouette é muito baixo (0,047 com k = 12) e os clusters correspondem a assuntos (política, futebol, loteria, operação Lava Jato), sem relação com as classes (ARI = −0,02).

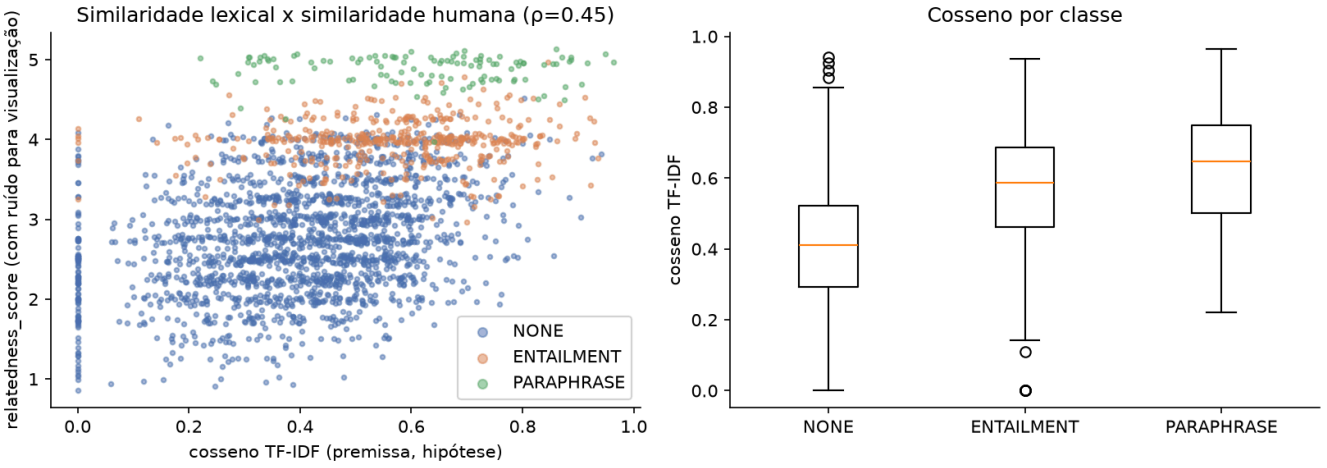
Cluster	n	none (%)	entailment (%)	paraphrase (%)
0	368	86,1	10,9	3,0
1	943	55,1	35,2	9,7
2	1189	93,4	5,5	1,2



3. Modelagem de tópicos (NMF). A fatoração não negativa do TF-IDF com 8 tópicos recupera assuntos coerentes: futebol (gol, jogo, minuto, partida), política (presidente, Dilma Rousseff, ministro, Senado), loterias (`R$` , bilhão, quina, prêmio), operação Lava Jato, balança comercial (superávit, `US$` , acumular), acidentes e vítimas (ferida, morrer, desaparecido), entre outros. O peso médio de cada tópico é parecido nas três classes (Figura 6); as diferenças são pequenas, e a classe paraphrase tem apenas 116 exemplos. Portanto o assunto do par não prevê a relação entre as frases.



4. Similaridade não supervisionada. O cosseno TF-IDF entre premissa e hipótese é uma medida de similaridade que não usa rótulos. Ele tem correlação de Spearman de 0,45 com o relatedness_score (0,58 para o índice de Jaccard), e sua AUC é de 0,77 para separar none das demais classes e de 0,76 para isolar paraphrase. O cosseno médio é 0,40 em none, 0,57 em entailment e 0,62 em paraphrase (Figura 7). A similaridade lexical, sozinha, já tem sinal, mas é limitada por não captar paráfrases com palavras diferentes nem negações.



5. Detecção de anomalias. O Isolation Forest, com 2% de contaminação, sinalizou 50 pares atípicos nos atributos de relação (31 none, 11 entailment e 8 paraphrase). A taxa de sinalização é maior em paraphrase (6,9%) que em none (1,6%) e entailment (2,5%). Os

pares mais atípicos incluem frases sem relação aparente classificadas como none e paráfrases com muitos números iguais. Atipicidade não significa erro de anotação, mas a lista serve para uma revisão manual.

2.7 Conclusões da análise exploratória

- O corpus é pequeno (2500 pares de treino), com vocabulário esparso e forte desbalanceamento (16,8:1).
- O assunto das frases não distingue as classes; o que as distingue é a relação entre premissa e hipótese.
- Sobreposição lexical, negação assimétrica e números iguais trazem sinal, mas sozinhos separam as classes apenas parcialmente. Isso sugere combinar atributos de relação com representações que capturem o significado.
- As técnicas não supervisionadas aplicadas (redução de dimensionalidade, agrupamento, tópicos, similaridade e anomalias) ajudam a interpretar os dados, mas não substituem um classificador supervisionado.

Questão 3 – Construção dos modelos

Esta etapa usa o corpus ASSIN (configuração ptbr), cuja tarefa é classificar pares de frases em none (0), entailment (1) e paraphrase (2). O treino tem 2500 pares (77,9%, 17,5% e 4,6% por classe), a validação tem 500 e o teste tem 2000.

3.1 Representação das features

A entrada textual de cada modelo é a concatenação dos lemas sem stopwords da premissa e da hipótese (com as negações preservadas). Foram comparadas duas representações, com a mesma configuração (palavras com ao menos 2 ocorrências, n-gramas 1–1 e 1–2) e ajustadas somente no treino: Bag-of-Words (CountVectorizer), que conta as ocorrências de cada palavra, e TF-IDF, que reduz o peso das palavras comuns.

Como a análise exploratória mostrou que o sinal está na relação entre as frases, também foram testados 11 atributos de relação: índice de Jaccard, proporção de cada frase contida na outra, número de lemas de cada frase e a diferença entre eles, presença de negação em cada frase e negação assimétrica, indicador de números iguais e quantidade de números da hipótese ausentes na premissa. Esses atributos são calculados apenas a partir do texto e padronizados com estatísticas do treino. O relatedness_score e o identificador dos pares não são usados, pois o escore é uma anotação humana associada ao rótulo e causaria vazamento.

3.2 Modelos e justificativa

Foram escolhidos quatro modelos, do mais simples ao mais flexível:

- **Naive Bayes multinomial:** estima a probabilidade de cada classe assumindo independência entre as palavras; é rápido e serve de referência. Não recebe os atributos de relação, pois exige valores não negativos.
- **Regressão logística:** pondera linearmente as features; é robusta em dados esparsos e interpretável.
- **SVM linear:** busca a fronteira de maior margem, adequada a muitas features esparsas.
- **MLP (uma camada oculta de 64 neurônios):** permite combinações não lineares entre as features.

3.3 Desbalanceamento e protocolo de validação

Como as classes são desbalanceadas (razão de 16,8:1 entre a maior e a menor), foram comparadas três estratégias, aplicadas apenas ao treino e nunca combinadas: nenhuma, pesos de classe (0,428; 1,907; 7,184) e oversampling aleatório até 1947 exemplos por classe. No Naive Bayes os pesos entram por sample_weight; o MLP do scikit-learn não aceita pesos e só usa oversampling.

Foram treinadas 212 configurações (modelo, vetorizador, n-grama, com ou sem atributos de relação, estratégia e hiperparâmetros) e avaliadas na validação pelo F1 macro, métrica principal porque a acurácia é enganosa: prever sempre none dá 76,8% de acurácia na validação, mas apenas 0,290 de F1 macro. O teste não foi usado nesta etapa.

3.4 Resultados na validação

Modelo	Vetorizador	n-grama / relação	Estratégia	F1 macro	F1 paraphrase
Naive Bayes	Count	1–2 / não	nenhuma	0,407	0,125
Regressão logística	TF-IDF	1–1 / sim	pesos	0,669	0,548
SVM linear	TF-IDF	1–1 / sim	pesos	0,681	0,604
MLP	TF-IDF	1–2 / sim	oversampling	0,656	0,571

Melhor configuração de cada modelo na validação.

Os atributos de relação foram o fator de maior efeito: sem eles, a regressão logística, o SVM e o MLP chegam a apenas 0,401, 0,386 e 0,354 de F1 macro, contra 0,669, 0,681 e 0,656 com eles. O tratamento do desbalanceamento também importou: no SVM, sem tratamento o F1 macro é 0,558 (F1 de paraphrase de 0,222), e com pesos sobe para 0,681 (0,604). Na comparação pareada, em que só o vetorizador muda, o TF-IDF superou o

Count em cerca de 0,02 de F1 macro na regressão logística, no SVM e no MLP, e foi pior no Naive Bayes (−0,03). O SVM escolheu C = 0,01, o menor valor testado, e o MLP escolheu o maior α testado; portanto, o ótimo pode estar fora do intervalo explorado.

Questão 4 – Avaliação quantitativa

Cada modelo foi avaliado no teste uma única vez, com a configuração escolhida na validação. Os intervalos de confiança de 95% foram obtidos por bootstrap (2000 reamostragens do teste).

4.1 Comparação dos modelos

Modelo	Configuração	Acurácia	Precision	Recall	F1 macro	IC 95% do F1 macro	F1 valid.
Baseline (sempre none)	–	0,776	0,259	0,333	0,291	[0,287; 0,295]	–
Naive Bayes	Count, 1–2, sem relação, nenhuma	0,714	0,415	0,373	0,378	[0,350; 0,405]	0,407
Regressão logística	TF-IDF, 1–1, relação, pesos	0,792	0,586	0,650	0,610	[0,579; 0,642]	0,669
SVM linear	TF-IDF, 1–1, relação, pesos	0,825	0,620	0,648	0,633	[0,598; 0,664]	0,681
MLP	TF-IDF, 1–2, relação, oversampling	0,820	0,626	0,586	0,599	[0,563; 0,635]	0,656

Desempenho no teste (médias macro; IC 95% do F1 macro).

Modelo	Classe	Precision	Recall	F1
Naive Bayes	none	0,794	0,874	0,832
Naive Bayes	entailment	0,245	0,188	0,213
Naive Bayes	paraphrase	0,207	0,057	0,089
Regressão logística	none	0,934	0,842	0,886
Regressão logística	entailment	0,505	0,674	0,578
Regressão logística	paraphrase	0,317	0,434	0,367
SVM linear	none	0,920	0,893	0,906
SVM linear	entailment	0,604	0,645	0,624

Modelo	Classe	Precision	Recall	F1
SVM linear	paraphrase	0,336	0,406	0,368
MLP	none	0,899	0,910	0,905
MLP	entailment	0,547	0,584	0,565
MLP	paraphrase	0,431	0,264	0,327

Precision, recall e F1 por classe no teste (suporte: 1553, 341 e 106 pares).

O SVM linear teve o maior F1 macro (0,633), contra 0,291 do baseline. Os intervalos do SVM, da regressão logística e do MLP se sobrepõem bastante, de modo que a vantagem do SVM não é conclusiva; já o Naive Bayes é claramente pior, pois seu limite superior (0,405) fica abaixo do limite inferior dos demais. A acurácia isolada é pouco informativa: o SVM supera o baseline em apenas 5 pontos de acurácia, mas mais que dobra o F1 macro. O F1 macro no teste foi de 0,03 a 0,06 inferior ao da validação (0,048 no SVM), sinal de algum otimismo da validação, que é pequena e foi usada para escolher entre 212 configurações; a ordem dos modelos se manteve. A classe paraphrase é a mais difícil (F1 de 0,368 no SVM; o MLP encontra apenas 28 dos 106 pares).

4.2 Matriz de confusão

Real \ Previsto	none	entailment	paraphrase
none	1387	113	53
entailment	89	220	32
paraphrase	32	31	43

Matriz de confusão do SVM linear no teste (linhas: classe real).

No SVM, paraphrase e entailment se confundem entre si (31 e 32 casos), e 53 pares none são classificados como paraphrase, o que reduz a precision dessa classe.

4.3 TF-IDF contra CountVectorizer

Modelo	F1 TF-IDF	F1 Count	Δ	IC 95% de Δ	F1 paraphrase TF-IDF	F1 paraphrase Count
Naive Bayes	0,375	0,378	−0,002	[−0,031; 0,027]	0,150	0,089
Regressão logística	0,610	0,602	0,008	[−0,015; 0,031]	0,367	0,335

Modelo	F1 TF-IDF	F1 Count	Δ	IC 95% de Δ	F1 paraphrase TF-IDF	F1 paraphrase Count
SVM linear	0,633	0,604	0,029	[−0,004; 0,060]	0,368	0,303
MLP	0,599	0,562	0,037	[0,008; 0,067]	0,327	0,264

TF-IDF contra Count no teste (F1 macro e F1 de paraphrase). Cada vetorizador usa sua melhor configuração na validação; Δ = TF-IDF − Count, com IC 95% por bootstrap pareado.

O TF-IDF teve F1 macro maior que o Count na regressão logística, no SVM e no MLP, e praticamente igual no Naive Bayes. A diferença só foi significativa no MLP (IC 95% de 0,008 a 0,067); no SVM ela fica próxima do limite, e nos demais não é conclusiva. Como cada vetorizador entra com a sua melhor configuração, a diferença pode refletir também outras escolhas (n-grama, atributos de relação, estratégia).

4.4 Análise dos erros

Dos 350 erros do SVM, 47% são pares none classificados como relacionados (113 como entailment e 53 como paraphrase). A acurácia cai de 0,96 nos pares de baixa sobreposição lexical para 0,62 nos de alta sobreposição, o que sugere que o modelo usa a sobreposição de palavras como atalho: nesse grupo, 47% dos pares são none, mas o modelo só prevê none em 33%. Entre os pares paraphrase, 59% são classificados incorretamente, e os exemplos examinados incluem paráfrases com vocabulário diferente (sinônimos e siglas, como “PF” e “Polícia Federal”), que a contagem de palavras não capta. Os erros em none têm relatedness_score médio maior (3,19) que os acertos (2,66), isto é, concentram-se em pares que os anotadores já consideravam parecidos. Parte da confusão entre entailment e paraphrase pode refletir subjetividade dos rótulos. Essas interpretações se baseiam em uma amostra pequena de exemplos e não foram quantificadas.

4.5 Discussão crítica e limitações

O SVM com TF-IDF, atributos de relação e pesos de classe teve o maior F1 macro. Três fatores parecem explicar o resultado: (i) os atributos de relação, que elevaram o F1 macro de cerca de 0,35–0,40 para 0,66–0,68 na validação, o que confirma que o sinal está na relação entre as frases e não no vocabulário; (ii) o tratamento do desbalanceamento, indispensável para a classe paraphrase; e (iii) o uso de modelos lineares regularizados, adequados a dados esparsos e pouco numerosos, enquanto o MLP, com mais parâmetros, não superou o SVM. O Naive Bayes, que ignora a relação entre as frases, ficou próximo do baseline.

Limitações:

- o bag-of-words ignora a ordem das palavras e não compara as duas frases; os atributos de relação compensam apenas parcialmente;
- a classe paraphrase tem 116 exemplos no treino, 24 na validação e 106 no teste, o que torna as estimativas dessa classe instáveis;
- foram avaliadas 212 configurações em 500 pares de validação, o que aumenta o risco de sobreajuste à validação;
- não foi feita comparação estatística pareada entre os modelos, apenas a observação da sobreposição dos intervalos;
- os rótulos de inferência têm componente subjetivo, e o corpus se restringe a textos jornalísticos.

Questão 5 – Conclusão

1. O que mais dificultou o processo? O forte desbalanceamento (16,8:1), que torna a acurácia enganosa e deixa a classe paraphrase com poucos exemplos; o tamanho reduzido do corpus; e o fato de a tarefa depender da relação entre duas frases, e não do assunto, o que limita representações baseadas em contagem de palavras. Também exigiu cuidado para evitar vazamento: ajustar vetorizadores só no treino, não usar o relatedness_score e usar o teste uma única vez.

2. Quais melhorias poderiam ser implementadas? No dataset: mais exemplos de paraphrase, revisão de rótulos duvidosos e textos de outros domínios. No pré-processamento: tratar trechos em inglês, revisar a lista de palavras protegidas (incluindo numerais e ordinais) e comparar lematização com stemming. Nos modelos: validação cruzada, busca de hiperparâmetros mais ampla (o SVM escolheu o menor C testado), testar o conjunto completo de atributos de relação e ensembles.

3. Como estender o projeto para aplicações reais? O mesmo classificador pode apoiar a checagem de fatos (uma afirmação é sustentada por um texto?), a detecção de perguntas ou notícias duplicadas, a avaliação automática de resumos e a busca semântica. Para uso real seria necessário medir o desempenho em dados de outros domínios e monitorar os erros nas classes raras.

4. Quais técnicas avançadas poderiam ser aplicadas em uma segunda versão? Fine-tuning de modelos pré-treinados em português, como o BERTimbau, recebendo premissa e hipótese juntas; embeddings de sentenças com similaridade entre os pares; aumento de dados para a classe minoritária; funções de perda ponderadas; e calibração das probabilidades.

Síntese

O melhor modelo foi o SVM linear com TF-IDF, atributos de relação e pesos de classe, com F1 macro de 0,633 no teste (IC 95%: 0,598–0,664), contra 0,291 da referência. A principal limitação é a dificuldade com a classe paraphrase (F1 de 0,368), pois a representação por contagem de palavras não capta sinônimos nem a relação semântica entre as frases.