

UNIVERSIDADE FEDERAL DO CEARÁ
CURSO DE CIÊNCIA DE DADOS

**Processamento de linguagem natural de sentimentos
das manchetes brasileiras**

**Análise e Classificação de Sentimentos em Manchetes
Jornalísticas**

Autores:

Suiany Pinto Gomes - 582147
Dayane Magalhães Ferreira - 587972
Hellen Lavyne Sousa Vasconcelos - 580524

Disciplina: Laboratório de Ciência de Dados
Professor(a): Alyson Bezerra Nogueira Ribeiro

Sumário

1	Introdução	3
2	Descrição do conjunto de dados	3
2.1	Variável textual utilizada	4
3	Metodologia	4
4	Pré-processamento dos textos	5
4.1	Conversão para letras minúsculas	5
4.2	Normalização Unicode	6
4.3	Remoção de caracteres especiais	6
4.4	Tokenização	6
4.5	Análise de registros duplicados	7
4.6	Lematização	7
5	Análise Exploratória do Corpus	7
5.1	Tamanho do corpus e número de classes	7
5.2	Distribuição das classes	8
5.3	Palavras mais frequentes no corpus	9
5.4	Nuvem de palavras	10
6	Conversão do corpus para dados numéricos	11
6.1	Aplicações de aprendizado não supervisionado	12
6.1.1	K-means	12
6.1.2	Escolha do número de clusters	12
6.1.3	Distribuição dos clusters	13
6.1.4	Características dos clusters	14
6.1.5	Relação entre os clusters e o sentimento	14
6.1.6	Análise complementar pelo Silhouette Score	16
6.2	Agrupamento hierárquico de notícias	16
6.2.1	Dendrograma – Single	17
6.2.2	Dendrograma – Complete	17
6.2.3	Dendrograma – Average	18
6.2.4	Comparação dos resultados da clusterização hierárquica	18
7	Aplicação 3 – Identificação de notícias semelhantes	19
8	Etapa 4 – Análise e discussão dos resultados	26
8.1	Identificação do melhor modelo	28
8.2	Discussão crítica	29

8.3	Limitações observadas	29
8.3.1	Limitações e possibilidades de melhoria	30
9	Etapa 5 – Conclusão	30
9.1	Qual foi a parte mais difícil do projeto?	30
9.2	Quais melhorias poderiam ser feitas no dataset, pré-processamento ou modelos?	31
9.3	Quais seriam aplicações reais desse tipo de classificação?	31
9.4	Quais técnicas avançadas poderiam ser utilizadas em uma segunda versão?	31
9.5	Conclusão geral	32

1 Introdução

O crescimento da quantidade de informações textuais disponíveis em meios digitais tem aumentado a importância de técnicas capazes de extrair informações relevantes de textos de maneira automática. Nesse contexto, o Processamento de Linguagem Natural (PLN) reúne técnicas computacionais voltadas para o processamento, análise e interpretação da linguagem humana.

Entre as diferentes aplicações de PLN está a análise de sentimentos, cujo objetivo é identificar informações relacionadas à polaridade ou ao sentimento presente em um texto. Dependendo do problema, os textos podem ser classificados como positivos, negativos ou neutros, ou ainda representados por valores numéricos que indicam a intensidade e a direção do sentimento.

Neste trabalho foi utilizado o conjunto de dados *brazilian_headlines_sentiments*, composto por manchetes jornalísticas e informações relacionadas ao sentimento associado a cada texto. A análise foi concentrada principalmente nas manchetes disponíveis em português.

O projeto envolve diferentes etapas desde o pré-processamento dos dados e leitura, incluindo limpeza dos dados, normalização, tokenização, lematização, análise exploratória até avaliação quantitativa dos resultados tendo acurácia, precisão, recall, F1-score, matriz de confusão.

Também são comparadas diferentes formas de representação textual, especificamente *Bag of Words* e TF-IDF, juntamente com diferentes algoritmos de aprendizado de máquina.

O objetivo geral deste trabalho é analisar as características textuais e de sentimento presentes nas manchetes e avaliar diferentes métodos de classificação de sentimentos utilizando técnicas de Processamento de Linguagem Natural.

2 Descrição do conjunto de dados

O conjunto de dados utilizado neste projeto é denominado *brazilian_headlines_sentiments*. Ele contém manchetes jornalísticas em português e inglês, além de variáveis relacionadas à análise de sentimentos e informações sobre a publicação das notícias.

Entre as variáveis presentes no conjunto de dados encontram-se:

- **website:** site de origem da manchete;
- **keywords:** palavras-chave associadas à notícia;
- **headlinePortuguese:** manchete em português;
- **headlineEnglish:** manchete em inglês;

- `sentimentScorePortuguese`: pontuação de sentimento da manchete em português;
- `sentimentScoreEnglish`: pontuação de sentimento da manchete em inglês;
- `sentimentMagnitudePortuguese`: magnitude do sentimento da manchete em português;
- `sentimentMagnitudeEnglish`: magnitude do sentimento da manchete em inglês;
- `isOnline`: informação relacionada à disponibilidade da notícia;
- `onlineStartDate`: data inicial de disponibilidade;
- `onlineEndDate`: data final de disponibilidade;
- `onlineTotalTimeMS`: tempo total de disponibilidade.

2.1 Variável textual utilizada

Neste projeto foi escolhida a variável `headlinePortuguese` como principal fonte textual para as análises.

Essa escolha permite que todas as etapas de pré-processamento sejam realizadas de forma consistente para textos em língua portuguesa, incluindo a remoção de ruídos, tokenização e lematização.

Além disso, como a análise está sendo realizada sobre as manchetes em português, a variável `sentimentScorePortuguese` foi utilizada como principal referência para o sentimento associado aos textos.

3 Metodologia

O desenvolvimento do projeto foi realizado de forma sequencial, contemplando desde a exploração e preparação do conjunto de dados até a aplicação e avaliação de técnicas de aprendizado de máquina. Inicialmente, foi realizada a inspeção da estrutura e das características do corpus. Em seguida, foram aplicadas etapas de pré-processamento dos textos, com o objetivo de preparar as manchetes para as análises posteriores.

Após o pré-processamento, foi realizada a análise exploratória do corpus, incluindo a distribuição das classes de sentimento, a frequência das palavras e diferentes visualizações. Posteriormente, os textos foram transformados em representações numéricas por meio de técnicas de vetorização, permitindo a aplicação de métodos de aprendizado não supervisionado e supervisionado.

As principais etapas adotadas foram:

1. carregamento e inspeção do conjunto de dados;

2. identificação de valores ausentes e registros duplicados;
3. normalização dos textos;
4. remoção de caracteres considerados ruídos;
5. tokenização;
6. lematização;
7. análise exploratória do corpus e das classes de sentimento;
8. análise da frequência de palavras e geração de visualizações;
9. transformação dos textos em representações numéricas utilizando TF-IDF e Count-Vectorizer;
10. aplicação de técnicas de aprendizado não supervisionado para exploração do corpus;
11. divisão dos dados em conjuntos de treinamento e teste;
12. treinamento de modelos de classificação;
13. avaliação dos modelos por meio de métricas de desempenho e matrizes de confusão;
14. comparação entre os modelos e as diferentes representações textuais;
15. identificação do melhor modelo e discussão dos resultados, limitações e possibilidades de melhoria.

4 Pré-processamento dos textos

O pré-processamento possui um papel importante em aplicações de Processamento de Linguagem Natural, pois textos reais podem apresentar caracteres desnecessários, variações de escrita e outros elementos que podem aumentar a quantidade de informações irrelevantes fornecidas aos modelos.

Dessa forma, diferentes etapas foram realizadas antes da transformação dos textos em representações numéricas.

4.1 Conversão para letras minúsculas

Inicialmente, todas as manchetes foram convertidas para letras minúsculas. Essa transformação permite reduzir variações causadas apenas pelo uso de letras maiúsculas e minúsculas.

Por exemplo, as palavras “Brasil” e “brasil” representam semanticamente a mesma palavra, porém poderiam ser interpretadas como elementos diferentes durante a representação numérica do texto.

Também foram removidos espaços desnecessários no início e no final das manchetes, além de múltiplos espaços entre palavras.

4.2 Normalização Unicode

Foi utilizada a normalização Unicode no formato NFC (*Normalization Form Canonical Composition*).

Essa etapa padroniza diferentes representações Unicode visualmente equivalentes, evitando que caracteres que aparentam ser iguais sejam interpretados computacionalmente como diferentes.

4.3 Remoção de caracteres especiais

Durante a exploração dos textos foram identificados alguns caracteres especiais que poderiam representar ruídos para a análise.

Entre os caracteres encontrados estavam aspas especiais, travessões, reticências, caracteres invisíveis e símbolos.

Após a identificação desses elementos, foi criada uma rotina para removê-los das manchetes.

Uma verificação posterior indicou que os caracteres considerados indesejados haviam sido removidos, permitindo continuar o processamento sobre textos mais padronizados.

4.4 Tokenização

Após a limpeza inicial foi realizada a tokenização das manchetes.

A tokenização consiste em dividir um texto em unidades menores chamadas *tokens*. Neste trabalho, os tokens representam principalmente as palavras presentes em cada manchete.

Como exemplo, a manchete:

“bolsonaro se desculpa após mandar repórter calar a boca fui grosseiro”

pode ser representada como:

```
[bolsonaro, se, desculpa, após, mandar, repórter, calar, a, boca, fui,
grosseiro]
```

A biblioteca NLTK foi utilizada para auxiliar nessa etapa.

4.5 Análise de registros duplicados

Também foi realizada uma análise de possíveis registros duplicados.

Inicialmente, a verificação considerando todas as colunas não apresentou linhas completamente duplicadas. Entretanto, ao analisar especificamente a coluna `headlinePortuguese`, foram identificadas manchetes que apareciam mais de uma vez no conjunto de dados.

Foram identificadas **674 manchetes duplicadas** durante essa etapa da análise.

Essa verificação é importante porque registros repetidos podem influenciar análises de frequência e também causar distorções durante o treinamento e a avaliação dos modelos.

4.6 Lematização

Após a tokenização foi realizada a lematização.

A lematização busca transformar palavras flexionadas em suas formas básicas ou formas de dicionário. Diferentemente de técnicas como o *stemming*, que normalmente realizam cortes nas palavras, a lematização procura preservar melhor seu significado linguístico.

Por exemplo:

Tabela 1: Exemplos de lematização

Palavra original	Lema
defendeu	defender
dá	dar
fui	ser

A opção pela lematização foi adotada porque as palavras resultantes mantêm maior proximidade com formas linguisticamente válidas.

Ao final do procedimento, todas as **9.027 manchetes** analisadas apresentaram resultado de lematização, sem valores ausentes nessa etapa.

5 Análise Exploratória do Corpus

Esta etapa tem como objetivo compreender as principais características do corpus antes da aplicação dos modelos de aprendizado de máquina. Foram analisados o tamanho do corpus, o número e a distribuição das classes de sentimento, além da frequência das palavras presentes nas manchetes.

5.1 Tamanho do corpus e número de classes

O corpus é o conjunto de textos que será analisado. Neste trabalho, o corpus é composto por **9.027 manchetes em português**, provenientes do conjunto de dados utilizado

no projeto.

Após as etapas de pré-processamento, as manchetes passaram a contar também com representações tokenizadas e lematizadas. Além disso, foi criada a variável categórica **sentimento**, utilizada como variável-alvo na etapa de classificação.

A variável **sentimentScorePortuguese** foi utilizada para definir três classes de sentimento. Valores menores que zero foram classificados como **negativos**, valores iguais a zero como **neutros** e valores maiores que zero como **positivos**.

Assim, o problema de classificação considerado neste trabalho possui **três classes**: negativo, neutro e positivo.

A quantidade de registros e de colunas do conjunto de dados após as etapas realizadas pode ser observada a seguir:

Tabela 2: Dimensões do corpus analisado

Característica	Quantidade
Número de manchetes	9.027
Número de colunas	16
Número de classes	3

5.2 Distribuição das classes

A distribuição das classes de sentimento foi analisada a partir da variável **sentimento**. Os resultados obtidos são apresentados na Tabela 3.

Tabela 3: Distribuição das classes de sentimento

Classe	Quantidade	Percentual
Positivo	3.889	43,08%
Neutro	2.692	29,82%
Negativo	2.446	27,10%
Total	9.027	100,00%

Observa-se que a classe **positiva** possui a maior quantidade de registros, com 3.889 manchetes (43,08%). A classe **neutra** possui 2.692 registros (29,82%) e a classe **negativa** possui 2.446 registros (27,10%).

Apesar da diferença entre as classes, não foi observada uma concentração extrema dos registros em apenas uma delas. A maior classe representa 43,08% do corpus, enquanto a menor representa 27,10%. Dessa forma, optou-se por manter a composição original dos dados, sem aplicação de técnicas de reamostragem.

Na etapa de classificação, o desempenho dos modelos será avaliado separadamente para cada classe por meio de métricas como precisão, revocação (recall) e F1-score. Essa

abordagem permitirá verificar se as diferenças na quantidade de exemplos entre as classes influenciam o desempenho dos modelos.




Figura 1: Distribuição das classes de sentimento no corpus.

A Figura 1 apresenta visualmente a distribuição das três classes. É possível observar que a classe positiva apresenta a maior frequência, enquanto as classes neutra e negativa possuem quantidades menores, mas relativamente próximas entre si.

5.3 Palavras mais frequentes no corpus

A análise da frequência das palavras foi realizada com o objetivo de identificar os termos mais recorrentes nas manchetes após o pré-processamento.

A Figura 2 apresenta as 20 palavras mais frequentes encontradas no corpus.




Figura 2: 20 palavras mais frequentes no corpus.

Observa-se uma frequência bastante elevada da palavra *Bolsonaro*, com 6.335 ocorrências. Em seguida aparecem termos como *dizer*, *moro*, *weintraub*, *sobre* e *pf*.

A elevada frequência de alguns termos está relacionada aos assuntos e às personalidades presentes nas notícias que compõem o corpus. A análise também permite identificar palavras que aparecem de forma recorrente em diferentes contextos das manchetes.

5.4 Nuvem de palavras

Como complemento à análise de frequência, foi construída uma nuvem de palavras. Essa representação permite visualizar de forma rápida os termos mais recorrentes do corpus, sendo que o tamanho de cada palavra está relacionado à sua frequência.

Também foi utilizada a representação **CountVectorizer**, que transforma cada manchete em um vetor contendo a quantidade de ocorrências de cada termo. Essa representação também produziu uma matriz de 9.027×5.660 , utilizando os mesmos 5.660 termos do vocabulário. A igualdade na dimensão ocorre porque ambas as técnicas foram aplicadas ao mesmo conjunto de lemas, com as mesmas stopwords e o mesmo padrão de tokenização.

A diferença entre as duas representações está na forma como os valores são atribuídos aos termos: o **CountVectorizer** utiliza diretamente a quantidade de ocorrências, enquanto o **TF-IDF** considera também a frequência do termo no conjunto de documentos. As duas representações serão utilizadas posteriormente na etapa de classificação para comparar o desempenho dos modelos supervisionados.

6.1 Aplicações de aprendizado não supervisionado

Após a conversão das manchetes para uma representação numérica, foi possível aplicar técnicas de aprendizado não supervisionado. O objetivo dessa etapa é verificar se existem agrupamentos ou estruturas semelhantes entre as manchetes sem utilizar previamente a classe de sentimento para formar esses grupos.

Foram exploradas duas abordagens de agrupamento: **K-means** e **clusterização hierárquica**.

6.1.1 K-means

A primeira aplicação de aprendizado não supervisionado foi o algoritmo **K-means**, utilizado para investigar se existem grupos de manchetes com características textuais semelhantes.

Para essa análise, foi utilizada a matriz TF-IDF, pois ela representa cada manchete numericamente considerando a importância dos termos presentes no corpus. As stopwords também foram removidas durante a vetorização, evitando que palavras funcionais muito frequentes influenciassem excessivamente os agrupamentos.

6.1.2 Escolha do número de clusters

Inicialmente, foi utilizado o **método do cotovelo**, considerando valores de k entre 2 e 10. Esse método analisa a inércia dos agrupamentos para auxiliar na escolha de um número adequado de clusters.




Figura 4: Método do cotovelo para diferentes valores de k no K-means.

A curva obtida não apresentou um ponto de cotovelo claramente definido. Portanto, não foi possível determinar de maneira inequívoca o número de clusters somente por esse critério. Para fins exploratórios, foi escolhido inicialmente $k = 6$, e os agrupamentos foram posteriormente analisados.

Para complementar essa escolha, foram comparados os valores de $k = 4$, $k = 5$ e $k = 6$ utilizando a **inércia** e o **Silhouette Score**:

Tabela 4: Comparação entre diferentes valores de k no K-means.

Número de clusters	Inércia	Silhouette Score
4	8785,4244	0,006769
5	8761,5143	0,006788
6	8731,6592	0,008168

Observa-se que a inércia diminui com o aumento do número de clusters. Entre os três valores avaliados, o $k = 6$ **apresentou o maior Silhouette Score**, com valor de **0,008168**. Entretanto, esse valor é baixo, indicando que os grupos possuem pouca separação entre si. Assim, o $k = 6$ foi utilizado como uma escolha exploratória, e não como uma evidência de que existem seis grupos naturalmente definidos no corpus.

6.1.3 Distribuição dos clusters

Com $k = 6$, o K-means foi aplicado ao corpus completo. A distribuição obtida foi:

Tabela 5: Distribuição das manchetes entre os clusters obtidos pelo K-means.

Cluster	Quantidade	Percentual
0	848	9,39%
1	1.337	14,81%
2	429	4,75%
3	814	9,02%
4	4.562	50,54%
5	1.037	11,49%

O **Cluster 4 concentra 50,54% das manchetes**, sendo significativamente maior que os demais agrupamentos. O Cluster 2, por outro lado, apresenta a menor quantidade de documentos, com 4,75%.

6.1.4 Características dos clusters

Para compreender melhor os agrupamentos, foram analisados os principais termos presentes nos centróides de cada cluster. Os resultados indicaram as seguintes possíveis temáticas:

Tabela 6: Principais termos e possíveis temáticas dos clusters.

Cluster	Principais termos	Possível temática
0	contra, PF, Bolsonaro, ação, interferência, inquérito, operação, STF, TSE, Ramagem	Investigações, ações e instituições
1	dizer, Bolsonaro, reunião, Brasil, ministro, auxílio, Lula, poder	Governo, ministros e decisões políticas
2	Flávio, Queiroz, Bolsonaro, advogado, prisão, rachadinha, PF	Flávio Bolsonaro e investigações
3	Weintraub, STF, banco, mundial, ministro, MEC, EUA, fake, governo	Weintraub, governo e assuntos institucionais
4	Bolsonaro, STF, governo, ministro, reunião, exame	Governo e Bolsonaro
5	Moro, vídeo, depoimento, Bolsonaro, PF, acusação, STF, ministro	Moro, Bolsonaro e depoimentos/investigações

Apesar dessas possíveis temáticas, existe uma considerável sobreposição entre os clusters. Termos como **“Bolsonaro”**, **“STF”**, **“PF”** e **“ministro”** aparecem em diferentes agrupamentos. Essa sobreposição é coerente com o baixo Silhouette Score obtido anteriormente, indicando que os grupos não apresentam uma separação forte.

6.1.5 Relação entre os clusters e o sentimento

Após a formação dos clusters, foi realizada uma análise cruzada entre os agrupamentos e as classes de sentimento. É importante destacar que **o sentimento não foi utilizado na construção dos clusters**. Ele foi utilizado somente posteriormente para verificar se havia alguma associação entre os agrupamentos textuais encontrados e as classes de sentimento.

Os percentuais encontrados foram:

Tabela 7: Distribuição percentual das classes de sentimento dentro de cada cluster.

Cluster	Negativo	Neutro	Positivo
0	29,36%	34,79%	35,85%
1	40,61%	32,91%	26,48%
2	22,14%	31,00%	46,85%
3	26,66%	30,59%	42,75%
4	23,43%	26,70%	49,87%
5	26,33%	34,43%	39,25%

O **Cluster 1** apresentou a maior proporção de manchetes negativas, com **40,61%**. Já o **Cluster 4** apresentou a maior proporção de manchetes positivas, com **49,87%**, seguido pelos Clusters 2 e 3, com 46,85% e 42,75%, respectivamente.

Os Clusters 0 e 5 apresentaram distribuições mais equilibradas entre as três classes, embora o sentimento positivo tenha sido predominante. Nenhum dos seis clusters apresentou o sentimento neutro como classe predominante.




Figura 5: Distribuição das classes de sentimento dentro dos clusters obtidos pelo K-means.

A visualização confirma os resultados obtidos na tabela. O Cluster 1 apresenta maior participação da classe negativa, enquanto os Clusters 2, 3 e 4 apresentam maior participação da classe positiva. No Cluster 4, aproximadamente metade das manchetes pertence à classe positiva.

Entretanto, esses resultados **não significam que o K-means classificou as manchetes por sentimento**. Os agrupamentos foram construídos exclusivamente a partir da representação TF-IDF. A comparação com o sentimento foi realizada posteriormente e possui caráter exploratório. Além disso, o baixo Silhouette Score indica que a separação entre os grupos é fraca.

6.1.6 Análise complementar pelo Silhouette Score

Como análise complementar, foi calculado o Silhouette Score para valores de k entre 2 e 20.

Os resultados variaram de **0,0054 para $k = 2$ até 0,0155 para $k = 20$** . O maior valor foi obtido para $k = 20$, **com Silhouette Score igual a 0,0155**.

Figura 6: Silhouette Score para diferentes valores de k no K-means.

Apesar de $k = 20$ apresentar o maior valor entre os casos avaliados, o Silhouette Score continua baixo. Isso indica que não há evidências de uma estrutura de clusters fortemente definida no corpus.

Assim, o $k = 6$ **utilizado na análise anterior deve ser entendido como uma escolha exploratória**, e não necessariamente como o número ótimo de agrupamentos. O aumento de k melhora gradualmente o Silhouette Score, mas os valores permanecem baixos, reforçando a dificuldade de encontrar grupos textuais claramente separados.

6.2 Agrupamento hierárquico de notícias

Como segunda abordagem de aprendizado não supervisionado, foi aplicada a **clusterização hierárquica** sobre uma amostra aleatória de **150 manchetes**, utilizando novamente a representação TF-IDF.

Foram avaliados três métodos de ligação:

- **Single;**
- **Complete;**
- **Average.**

Em todos os casos, foi utilizada a **distância euclidiana**.

6.2.1 Dendrograma – Single




Figura 7: Dendrograma da clusterização hierárquica utilizando o método Single.

O método **Single** apresenta uma estrutura característica de encadeamento, na qual as observações vão sendo incorporadas progressivamente aos grupos. Esse comportamento dificulta a identificação visual de uma quantidade natural de clusters.

6.2.2 Dendrograma – Complete




Figura 8: Dendrograma da clusterização hierárquica utilizando o método Complete.

O método **Complete** apresenta uma estrutura mais distribuída que o método Single. Entretanto, também não é observado um ponto de corte claramente definido que indique naturalmente uma quantidade específica de agrupamentos.

6.2.3 Dendrograma – Average




Figura 9: Dendrograma da clusterização hierárquica utilizando o método Average.

O método **Average** também não apresentou uma separação visual suficientemente clara para determinar naturalmente o número de clusters. Dessa forma, os dendrogramas, isoladamente, não fornecem uma indicação clara da quantidade ideal de agrupamentos.

6.2.4 Comparação dos resultados da clusterização hierárquica

De forma geral, os três métodos avaliados não apresentaram uma divisão natural e visualmente evidente dos dados. O método Single apresentou maior característica de encadeamento, enquanto Complete e Average produziram estruturas mais distribuídas, mas sem um ponto de corte claramente definido.

Assim, a clusterização hierárquica foi utilizada como uma **análise complementar ao K-means**, não sendo utilizada isoladamente para determinar o número de agrupamentos do corpus. Os resultados também reforçam a dificuldade de identificar grupos textuais claramente separados na representação TF-IDF utilizada.

Como etapa complementar, foi realizada uma tentativa de particionar a amostra de 150 manchetes em **até seis clusters**, utilizando o método Complete e o critério **maxclust**. Embora tenha sido definido $t = 6$, o procedimento resultou em **quatro clusters**, contendo respectivamente **66, 20, 29 e 35 manchetes**.

Esse resultado não confirma diretamente a estrutura de seis agrupamentos encontrada pelo K-means. Enquanto o K-means produziu seis clusters considerando o corpus completo, a clusterização hierárquica foi aplicada somente à amostra de 150 manchetes e resultou em quatro grupos. Essa diferença mostra que a estrutura encontrada depende do método de agrupamento utilizado e reforça que **não há uma estrutura de clusters claramente definida no corpus**.

7 Aplicação 3 – Identificação de notícias semelhantes

Q3.1 – Separação entre treinamento e teste

Para a divisão dos dados em treinamento e teste, foi utilizado o método `GroupShuffleSplit`, considerando a manchete lematizada como variável de agrupamento. Essa estratégia foi adotada para evitar que manchetes duplicadas fossem distribuídas simultaneamente entre os conjuntos de treinamento e teste, reduzindo o risco de vazamento de dados.

Foi utilizada uma proporção de 80% dos dados para treinamento e 20% para teste. Como resultado, foram obtidas 7.196 manchetes para treinamento e 1.831 para teste.

Tabela 8: Quantidade de manchetes nos conjuntos de treinamento e teste.

Conjunto	Quantidade	Proporção
Treinamento	7.196	80%
Teste	1.831	20%

Q3.2 – Verificação da distribuição das classes

Após a separação dos dados, foi verificada a distribuição das classes de sentimento nos conjuntos de treinamento e teste. Os resultados obtidos foram:

Tabela 9: Distribuição das classes nos conjuntos de treinamento e teste.

Conjunto	Quantidade	Positivo	Neutro	Negativo
Treinamento	7.196	43,30%	29,86%	26,83%
Teste	1.831	42,22%	29,66%	28,13%

As proporções são bastante próximas às observadas no corpus completo, composto por aproximadamente 43% de manchetes positivas, 30% de manchetes neutras e 27% de manchetes negativas.

Portanto, não houve uma distorção relevante das classes ao utilizar a divisão agrupada. Além disso, a estratégia garante que manchetes lematizadas idênticas não sejam colocadas simultaneamente nos conjuntos de treinamento e teste.

Q3.3 – Aplicação do TF-IDF

Para transformar as manchetes em uma representação numérica, foi utilizado o método TF-IDF (*Term Frequency – Inverse Document Frequency*). A representação foi ajustada utilizando apenas os dados de treinamento e, posteriormente, aplicada ao conjunto de teste. Essa estratégia evita que informações do conjunto de teste sejam utilizadas durante o treinamento.

A matriz TF-IDF obtida apresentou 7.196 documentos e 5.163 termos no conjunto de treinamento. No conjunto de teste, foram mantidos os mesmos 5.163 termos da representação aprendida no treinamento.

Tabela 10: Dimensões da representação TF-IDF.

Conjunto	Dimensão
Treinamento	7.196×5.163
Teste	1.831×5.163

Q3.4 – Primeiro modelo: Naive Bayes

O primeiro modelo de classificação utilizado foi o Multinomial Naive Bayes, aplicado sobre a representação TF-IDF. O modelo foi treinado com o conjunto de treinamento e posteriormente utilizado para realizar as previsões sobre o conjunto de teste.

Q3.5 – Avaliação do Naive Bayes

O modelo Multinomial Naive Bayes apresentou os seguintes resultados:

Tabela 11: Desempenho do Naive Bayes com TF-IDF.

Métrica	Resultado
Accuracy	0,5576
Precision ponderada	0,5639
Recall ponderado	0,5576
F1-score ponderado	0,5355

A acurácia de 55,76% indica que o modelo classificou corretamente aproximadamente 55,76% das manchetes do conjunto de teste.

A análise individual das classes apresentou os seguintes resultados:

Tabela 12: Desempenho do Naive Bayes por classe.

Classe	Precision	Recall	F1-score	Suporte
Negativo	0,6980	0,4039	0,5117	515
Neutro	0,4419	0,3149	0,3677	543
Positivo	0,5602	0,8305	0,6691	773

Na classe negativa, a precisão foi relativamente alta, com valor de 69,80%. Isso significa que, quando o modelo classificou uma manchete como negativa, essa previsão estava correta em uma proporção relativamente alta. Por outro lado, o recall foi de apenas 40,39%, indicando que o modelo deixou de identificar uma parcela considerável das manchetes que realmente eram negativas.

A classe neutra apresentou o pior desempenho entre as três classes, com precisão de 44,19%, recall de 31,49% e F1-score de 36,77%. Esses resultados indicam que o modelo apresentou dificuldade para distinguir manchetes neutras das demais classes.

A classe positiva apresentou o maior recall, de 83,05%, indicando que o modelo conseguiu identificar a maior parte das manchetes que realmente eram positivas. O F1-score também foi o maior entre as três classes, atingindo 66,91%.

Matriz de confusão – Naive Bayes




Figura 10: Matriz de confusão do modelo Naive Bayes com TF-IDF.

A matriz de confusão permite observar de forma mais detalhada os acertos e erros do modelo.

Tabela 13: Matriz de confusão do Naive Bayes com TF-IDF.

Real \ Predita	Negativo	Neutro	Positivo
Negativo	208	119	188
Neutro	56	171	316
Positivo	34	97	642

Os valores da diagonal principal representam as classificações corretas. Assim, foram classificadas corretamente 208 manchetes negativas, 171 manchetes neutras e 642 manchetes positivas.

O principal erro ocorreu na classe neutra, com 316 manchetes realmente neutras classificadas como positivas. Esse resultado ajuda a explicar o baixo recall obtido pela classe neutra.

Também foram observadas 188 manchetes realmente negativas classificadas como positivas. Dessa forma, o modelo apresentou uma quantidade considerável de previsões positivas, sendo importante verificar se outro modelo de classificação consegue produzir uma distribuição de erros mais equilibrada.

Q3.6 – Regressão Logística + TF-IDF

Como segundo modelo, foi utilizada a Regressão Logística, também aplicada sobre a representação TF-IDF. O modelo foi treinado utilizando exatamente os mesmos conjuntos de treinamento e teste utilizados no Naive Bayes, permitindo uma comparação consistente entre os algoritmos.

Q3.7 – Avaliação da Regressão Logística

A Regressão Logística apresentou os seguintes resultados:

Tabela 14: Comparação entre Naive Bayes e Regressão Logística utilizando TF-IDF.

Métrica	Naive Bayes	Regressão Logística
Accuracy	0,5576	0,5816
Precision	0,5639	0,5744
Recall	0,5576	0,5816
F1-score	0,5355	0,5714

A Regressão Logística apresentou desempenho superior ao Naive Bayes em todas as métricas globais avaliadas.

O desempenho por classe foi:

Tabela 15: Desempenho da Regressão Logística com TF-IDF por classe.

Classe	Precision	Recall	F1-score
Negativo	0,6441	0,5165	0,5733
Neutro	0,4447	0,3702	0,4040
Positivo	0,6190	0,7736	0,6878

A classe positiva continuou sendo a mais bem identificada, com recall de 77,36% e F1-score de 68,78%. A classe neutra permaneceu como a mais difícil de classificar, apresentando F1-score de 40,40%.

Tabela 16: Matriz de confusão da Regressão Logística com TF-IDF.

Real \ Predita	Negativo	Neutro	Positivo
Negativo	266	134	115
Neutro	89	201	253
Positivo	58	117	598

Matriz de confusão – Regressão Logística + TF-IDF




Figura 11: Matriz de confusão da Regressão Logística com TF-IDF.

A matriz de confusão mostra que a Regressão Logística classificou corretamente 266 manchetes negativas, 201 neutras e 598 positivas.

O maior erro ocorreu quando manchetes realmente neutras foram classificadas como positivas, totalizando 253 casos. Esse resultado está relacionado ao baixo recall da classe neutra, de 37,02%.

Também é possível observar que a quantidade de manchetes negativas classificadas como positivas diminuiu de 188, no Naive Bayes, para 115 na Regressão Logística. Da mesma forma, as classificações corretas da classe negativa aumentaram de 208 para 266, enquanto as classificações corretas da classe neutra aumentaram de 171 para 201.

Apesar da redução das classificações corretas da classe positiva, que passaram de 642 para 598, a Regressão Logística apresentou desempenho geral superior.

Conclusão da comparação entre Naive Bayes e Regressão Logística

Na comparação entre os modelos, a Regressão Logística apresentou desempenho superior ao Multinomial Naive Bayes quando utilizada em conjunto com a representação TF-IDF. A acurácia aumentou de 55,76% para 58,16%, enquanto o F1-score ponderado passou de 53,55% para 57,14%. Também foram observados aumentos na precisão e no recall ponderados.

Na análise por classe, a Regressão Logística apresentou melhoria principalmente na identificação das classes negativa e neutra. O número de manchetes negativas classificadas corretamente aumentou de 208, no Naive Bayes, para 266, enquanto as classificações corretas da classe neutra aumentaram de 171 para 201. Por outro lado, a quantidade de manchetes positivas corretamente classificadas diminuiu de 642 para 598.

Apesar dessa redução na identificação da classe positiva, a Regressão Logística apresentou melhor desempenho geral. A classe neutra permaneceu como a mais difícil de classificar nos dois modelos, indicando maior dificuldade em distinguir manchetes neutras das demais classes.

Q3.8 – Representação com CountVectorizer

Além do TF-IDF, foi utilizada a representação CountVectorizer, que representa os textos por meio da frequência de ocorrência dos termos. A transformação foi ajustada apenas sobre o conjunto de treinamento e, posteriormente, aplicada ao conjunto de teste.

A matriz resultante apresentou as mesmas dimensões para os dois conjuntos:

Tabela 17: Dimensões da representação CountVectorizer.

Conjunto	Dimensão
Treinamento	7.196×5.163
Teste	1.831×5.163

Q3.9 – Naive Bayes + CountVectorizer

O Naive Bayes foi novamente treinado, desta vez utilizando a representação CountVectorizer.

Os resultados obtidos foram:

Tabela 18: Desempenho do Naive Bayes utilizando TF-IDF e CountVectorizer.

Métrica	Naive Bayes + TF-IDF	Naive Bayes + CountVectorizer
Accuracy	0,5576	0,5707
Precision	0,5639	0,5697
Recall	0,5576	0,5707
F1-score	0,5355	0,5681




Figura 12: Matriz de confusão do modelo Naive Bayes com CountVectorizer.

O Naive Bayes com CountVectorizer apresentou desempenho superior ao Naive Bayes com TF-IDF em todas as métricas globais. A acurácia aumentou de 55,76% para 57,07%, enquanto o F1-score ponderado passou de 53,55% para 56,81%.

O desempenho por classe foi:

Tabela 19: Desempenho do Naive Bayes com CountVectorizer por classe.

Classe	Precision	Recall	F1-score
Negativo	0,6112	0,5068	0,5541
Neutro	0,4349	0,4365	0,4357
Positivo	0,6368	0,7076	0,6703

Um resultado importante foi a melhoria na identificação da classe neutra. Seu recall aumentou de 31,49%, com TF-IDF, para 43,65%, com CountVectorizer. Apesar da melhoria, a classe neutra continuou apresentando o menor F1-score entre as três classes.

Na matriz de confusão, foram observados 261 negativos, 237 neutros e 547 positivos classificados corretamente. Dessa forma, a distribuição de acertos entre as classes tornou-se mais equilibrada em comparação ao Naive Bayes utilizando TF-IDF.

Q3.10 – Regressão Logística + CountVectorizer

Por fim, foi avaliada a Regressão Logística utilizando a representação CountVectorizer. Os resultados obtidos foram:

Tabela 20: Desempenho da Regressão Logística com CountVectorizer.

Métrica	Resultado
Accuracy	0,6002
Precision	0,5943
Recall	0,6002
F1-score	0,5943

O desempenho por classe foi:

Tabela 21: Desempenho da Regressão Logística com CountVectorizer por classe.

Classe	Precision	Recall	F1-score
Negativo	0,6355	0,5417	0,5849
Neutro	0,4676	0,4254	0,4455
Positivo	0,6559	0,7620	0,7050

A classe positiva continuou apresentando o melhor desempenho, com F1-score de 70,50% e recall de 76,20%. A classe neutra permaneceu como a mais difícil de classificar, apresentando F1-score de 44,55% e recall de 42,54%.

8 Etapa 4 – Análise e discussão dos resultados

Comparação dos quatro experimentos

Foram avaliadas quatro combinações entre modelos de classificação e representações numéricas: Multinomial Naive Bayes com TF-IDF, Multinomial Naive Bayes com CountVectorizer, Regressão Logística com TF-IDF e Regressão Logística com CountVectorizer.

A comparação foi realizada utilizando os mesmos conjuntos de treinamento e teste, obtidos por meio da divisão agrupada, permitindo uma comparação consistente entre os quatro experimentos.

Tabela 22: Comparação dos quatro experimentos de classificação.

Modelo	Representação	Accuracy	Precision	Recall	F1-score
Naive Bayes	TF-IDF	0,5576	0,5639	0,5576	0,5355
Naive Bayes	CountVectorizer	0,5707	0,5697	0,5707	0,5681
Regressão Logística	TF-IDF	0,5816	0,5744	0,5816	0,5714
Regressão Logística	CountVectorizer	0,6002	0,5943	0,6002	0,5943

Os resultados mostraram que a Regressão Logística apresentou desempenho superior ao Naive Bayes nas duas representações utilizadas. Com TF-IDF, a Regressão Logística obteve acurácia de 58,16% e F1-score ponderado de 57,14%, enquanto o Naive Bayes apresentou 55,76% de acurácia e 53,55% de F1-score.

Também foi observado que, para os dois modelos avaliados, o CountVectorizer apresentou resultados superiores ao TF-IDF. O melhor resultado foi obtido pela Regressão Logística utilizando CountVectorizer, com acurácia de 60,02%, precisão ponderada de 59,43%, recall ponderado de 60,02% e F1-score ponderado de 59,43%.

Análise por classe do melhor modelo

Para a Regressão Logística com CountVectorizer, a matriz de confusão foi:

Tabela 23: Matriz de confusão da Regressão Logística com CountVectorizer.

Real \ Predita	Negativo	Neutro	Positivo
Negativo	279	136	100
Neutro	103	231	209
Positivo	57	127	589

A diagonal da matriz apresenta os acertos do modelo: 279 manchetes negativas, 231 manchetes neutras e 589 manchetes positivas.

O maior número de erros ocorre quando manchetes neutras são classificadas como positivas, totalizando 209 casos. Esse resultado está de acordo com o recall da classe neutra, que foi de 42,54%.

Por outro lado, o modelo conseguiu identificar corretamente 76,20% das manchetes positivas, resultando em F1-score de 70,50% para essa classe.




Figura 13: Matriz de confusão da Regressão Logística com CountVectorizer.

Os quatro experimentos realizados permitiram comparar dois modelos de classificação, Multinomial Naive Bayes e Regressão Logística, utilizando duas diferentes representações textuais, TF-IDF e CountVectorizer.

Os resultados mostraram que a Regressão Logística apresentou desempenho superior ao Naive Bayes nas duas representações avaliadas. Além disso, o CountVectorizer apresentou resultados superiores ao TF-IDF para ambos os modelos.

A melhor configuração foi a Regressão Logística com CountVectorizer, que obteve acurácia de 60,02%, precisão ponderada de 59,43%, recall ponderado de 60,02% e F1-score ponderado de 59,43%.

Na análise das classes, a classe positiva apresentou o melhor desempenho no modelo selecionado, com F1-score de 70,50% e recall de 76,20%. A classe neutra apresentou maior dificuldade de classificação, com F1-score de 44,55% e recall de 42,54%. A matriz de confusão mostrou que 209 manchetes realmente neutras foram classificadas como positivas, constituindo uma das principais fontes de erro do modelo.

Dessa forma, considerando as métricas avaliadas, a Regressão Logística com CountVectorizer foi selecionada como a melhor configuração entre as alternativas testadas neste trabalho. Entretanto, seu desempenho ainda apresenta limitações, principalmente na identificação da classe neutra, indicando possibilidades de melhoria no pré-processamento, na representação textual e nos algoritmos utilizados.

Tabela 24: Resumo final dos resultados da Parte 3.

Modelo	Representação	Accuracy	Precision	Recall	F1-score
Naive Bayes	TF-IDF	55,76%	56,39%	55,76%	53,55%
Naive Bayes	CountVectorizer	57,07%	56,97%	57,07%	56,81%
Regressão Logística	TF-IDF	58,16%	57,44%	58,16%	57,14%
Regressão Logística	CountVectorizer	60,02%	59,43%	60,02%	59,43%

Assim, a melhor configuração encontrada foi a **Regressão Logística com CountVectorizer**. A principal dificuldade observada foi a classificação da classe **neutra**, que apresentou F1-score de 44,55%. Por outro lado, o principal ponto positivo foi o desempenho na classe **positiva**, que apresentou F1-score de 70,50%.

Metodologicamente, a comparação entre os quatro experimentos foi realizada de forma consistente, pois todos utilizaram a mesma divisão agrupada entre treinamento e teste, evitando que manchetes lematizadas idênticas fossem distribuídas simultaneamente nos dois conjuntos.

8.1 Identificação do melhor modelo

Para identificar a melhor configuração entre os quatro experimentos realizados, foi utilizada a métrica F1-score como critério de comparação. O maior valor de F1-score foi obtido pela Regressão Logística utilizando a representação CountVectorizer.

```
melhor_modelo = tabela_modelos.loc[
    tabela_modelos['F1-score'].idxmax()
```

]

```
print("Melhor configuração:")  
print(melhor_modelo)
```

O resultado obtido foi:

Melhor configuração:

Modelo	Regressão Logística
Representação	CountVectorizer
Accuracy	0.6002
Precision	0.5943
Recall	0.6002
F1-score	0.5943

Dessa forma, a Regressão Logística com CountVectorizer foi identificada como a melhor configuração entre os modelos avaliados, apresentando accuracy de 60,02%, precision de 59,43%, recall de 60,02% e F1-score de 59,43%.

8.2 Discussão crítica

A avaliação quantitativa mostrou diferenças de desempenho entre os modelos e as representações utilizadas. O pior resultado foi obtido pelo Naive Bayes com TF-IDF, que apresentou accuracy de 55,76% e F1-score de 53,55%. Ao utilizar o CountVectorizer com o mesmo modelo, houve uma melhoria, elevando a accuracy para 57,07% e o F1-score para 56,81%.

A Regressão Logística apresentou desempenho superior ao Naive Bayes nas duas representações avaliadas. Com TF-IDF, obteve accuracy de 58,16% e F1-score de 57,14%. Já com CountVectorizer, apresentou o melhor desempenho entre todas as configurações, alcançando accuracy de 60,02%, precision de 59,43%, recall de 60,02% e F1-score de 59,43%.

Portanto, considerando o conjunto de dados e as configurações utilizadas neste experimento, a Regressão Logística associada ao CountVectorizer foi selecionada como o melhor modelo. Os resultados indicam que, para este corpus, a representação baseada na frequência dos termos apresentou desempenho superior à representação TF-IDF nos dois classificadores avaliados.

8.3 Limitações observadas

A principal limitação observada foi a dificuldade de classificação da classe neutra. No melhor modelo, baseado em Regressão Logística e CountVectorizer, a classe negativa

apresentou F1-score de 58,49%, a classe neutra apresentou F1-score de 44,55% e a classe positiva apresentou F1-score de 70,50%.

A matriz de confusão mostrou ainda que 209 manchetes que pertenciam à classe neutra foram classificadas como positivas, indicando uma dificuldade do modelo em distinguir essas duas classes.

8.3.1 Limitações e possibilidades de melhoria

Entre as principais limitações identificadas, destaca-se a dificuldade de classificação da classe neutra. No melhor modelo, essa classe apresentou recall de 42,54% e F1-score de 44,55%, enquanto a classe positiva apresentou F1-score de 70,50%. A matriz de confusão também mostrou que 209 manchetes neutras foram classificadas como positivas, indicando dificuldade na distinção entre essas classes.

Outra limitação está relacionada à utilização de manchetes como fonte textual. Por serem textos curtos, as manchetes podem apresentar pouco contexto para que o modelo identifique corretamente o sentimento. Além disso, determinadas palavras podem assumir diferentes sentidos dependendo do contexto em que são utilizadas.

As representações TF-IDF e CountVectorizer utilizadas neste trabalho também apresentam limitações, pois representam os textos principalmente a partir da frequência dos termos e não capturam completamente aspectos semânticos e contextuais da linguagem. Dessa forma, características como ironia, ambiguidade e relações entre palavras podem não ser adequadamente representadas.

Como possibilidades de melhoria, poderiam ser testadas técnicas mais avançadas de representação textual, como embeddings de palavras ou representações contextuais obtidas por modelos de linguagem. Também poderiam ser avaliados outros algoritmos de classificação, ajustes de hiperparâmetros e estratégias específicas para melhorar a identificação da classe neutra. Essas alternativas poderiam contribuir para aumentar o desempenho do classificador e reduzir os erros observados na matriz de confusão.

9 Etapa 5 – Conclusão

9.1 Qual foi a parte mais difícil do projeto?

A etapa mais desafiadora foi o tratamento e a representação dos textos, especialmente a definição das etapas de pré-processamento e a escolha da melhor forma de transformar as manchetes em dados numéricos. Também foi necessário analisar as características do corpus, incluindo a presença de registros duplicados e a distribuição das classes de sentimento.

Outro ponto de dificuldade foi a comparação entre diferentes modelos e representações textuais, uma vez que o desempenho não depende apenas do algoritmo utilizado,

mas também da forma como os textos são representados. Os experimentos realizados permitiram observar diferenças entre TF-IDF e CountVectorizer e entre os modelos Naive Bayes e Regressão Logística.

9.2 Quais melhorias poderiam ser feitas no dataset, pré-processamento ou modelos?

Em relação ao conjunto de dados, poderiam ser realizadas análises mais aprofundadas das manchetes duplicadas e da qualidade dos rótulos de sentimento. No pré-processamento, poderiam ser testadas diferentes estratégias de remoção de ruído, stopwords e normalização, avaliando seus impactos sobre o desempenho dos classificadores.

Em relação aos modelos, poderiam ser avaliados outros algoritmos de classificação, diferentes configurações de hiperparâmetros e técnicas específicas para melhorar a identificação da classe neutra, que apresentou o menor desempenho no experimento. Também poderiam ser testadas representações textuais mais avançadas, capazes de capturar melhor o significado e o contexto das palavras.

9.3 Quais seriam aplicações reais desse tipo de classificação?

A classificação automática de sentimentos pode ser utilizada em diferentes aplicações reais, como análise de opiniões em redes sociais, monitoramento de notícias, acompanhamento da percepção pública sobre determinados acontecimentos ou organizações e análise automática de grandes volumes de textos.

Em um contexto jornalístico, por exemplo, modelos desse tipo podem auxiliar na organização e análise de grandes coleções de manchetes, permitindo identificar tendências de sentimento ao longo do tempo. Em empresas, a classificação de sentimentos também pode ser utilizada para analisar comentários, avaliações e opiniões de clientes.

9.4 Quais técnicas avançadas poderiam ser utilizadas em uma segunda versão?

Em uma segunda versão do projeto, poderiam ser utilizadas técnicas mais avançadas de Processamento de Linguagem Natural, principalmente representações baseadas em embeddings e modelos de linguagem contextualizados. Modelos baseados em Transformers poderiam ser utilizados para capturar relações semânticas e contextuais que não são representadas de forma completa pelo CountVectorizer e pelo TF-IDF.

Também poderiam ser exploradas técnicas de ajuste de hiperparâmetros, validação cruzada, balanceamento das classes e modelos mais sofisticados de classificação. Essas abordagens poderiam contribuir principalmente para melhorar a identificação da classe neutra e reduzir os erros observados na matriz de confusão.

9.5 Conclusão geral

O projeto permitiu aplicar diferentes etapas de Processamento de Linguagem Natural a um corpus de 9.027 manchetes, envolvendo pré-processamento, normalização, remoção de ruídos, tokenização, lematização, análise exploratória e transformação dos textos em representações numéricas. A análise exploratória permitiu identificar a distribuição das classes de sentimento e os termos mais frequentes do corpus, além de explorar possibilidades de aprendizagem não supervisionada por meio de técnicas de agrupamento.

Na etapa de classificação, foram comparados os modelos Naive Bayes e Regressão Logística utilizando as representações TF-IDF e CountVectorizer. Entre as quatro configurações avaliadas, a Regressão Logística com CountVectorizer apresentou o melhor desempenho, alcançando 60,02% de accuracy e 59,43% de F1-score ponderado.

Apesar do melhor resultado, a análise por classe mostrou que o modelo apresentou maior dificuldade na classificação das manchetes neutras, que obtiveram F1-score de 44,55%. Esse resultado evidencia que a classificação de sentimentos em textos curtos ainda apresenta desafios, principalmente pela quantidade limitada de contexto disponível nas manchetes.

Dessa forma, o projeto demonstrou a importância das etapas de pré-processamento e representação textual para o desempenho dos modelos de aprendizado de máquina. Como continuidade, técnicas mais avançadas de representação semântica e modelos contextualizados poderiam ser utilizadas para buscar melhorias no desempenho, especialmente na identificação da classe neutra.