Análise e classificação de textos em português

Estudo do corpus ASSIN (Avaliação de Similaridade Semântica e Inferência Textual)

Qual é o problema que estamos investigando?

Comparar duas frases vai além de comparar palavras

PREMISSA (é a frase que usamos como ponto de partida, ou seja, a informação que temos)

O atleta marcou dois gols na partida.

HIPÓTESE (é a frase que comparamos com a premissa para verificar se existe uma relação entre as duas)

O jogador fez dois gols no jogo.

A tarefa do ASSIN é analisar a relação entre as duas frases e classificá-la.

As três classes do ASSIN

0 - NONE (Sem implicação)

as frases não estabelecem a relação necessária.

1 - ENTAILMENT (Implicação)

a informação da primeira frase permite concluir a segunda.

2 - PARAPHRASE (Paráfrase)

as duas frases dizem praticamente a mesma coisa, mesmo usando palavras diferentes.

Questão 1: como preparamos os textos?

Objetivo: padronizar os textos sem perder informações importantes para interpretar a relação entre as frases.

1. Auditoria dos dados
   - Verificamos valores ausentes, frases vazias e pares duplicados.
   - Resultado: nenhum desses problemas foi encontrado nos conjuntos analisados.

2. Normalização e limpeza
   - Padronizamos aspas, travessões e espaços.
   - A limpeza foi conservadora, pois quase não havia ruídos relevantes.
   - Preservamos acentos, números, moedas e porcentagens, pois podem mudar o significado.

3. Tokenização com spaCy
   - Separamos as frases em palavras e outras unidades.
   - Utilizamos uma biblioteca de Python própria para processamento de linguagem natural.

4. Lematização
   - Reduzimos palavras às suas formas básicas.
   - Exemplo: “correndo” → “correr”.
   - Preferimos essa abordagem ao stemming, que pode cortar palavras sem produzir formas linguísticas corretas.

5. Criação de versões textuais
   - Mantivemos versões com texto limpo, tokens, lemas e lemas sem stopwords.
   - Na versão sem stopwords, protegemos palavras como “não”, “nunca”, “sem” e “mas”, pois podem alterar a interpretação das frases.

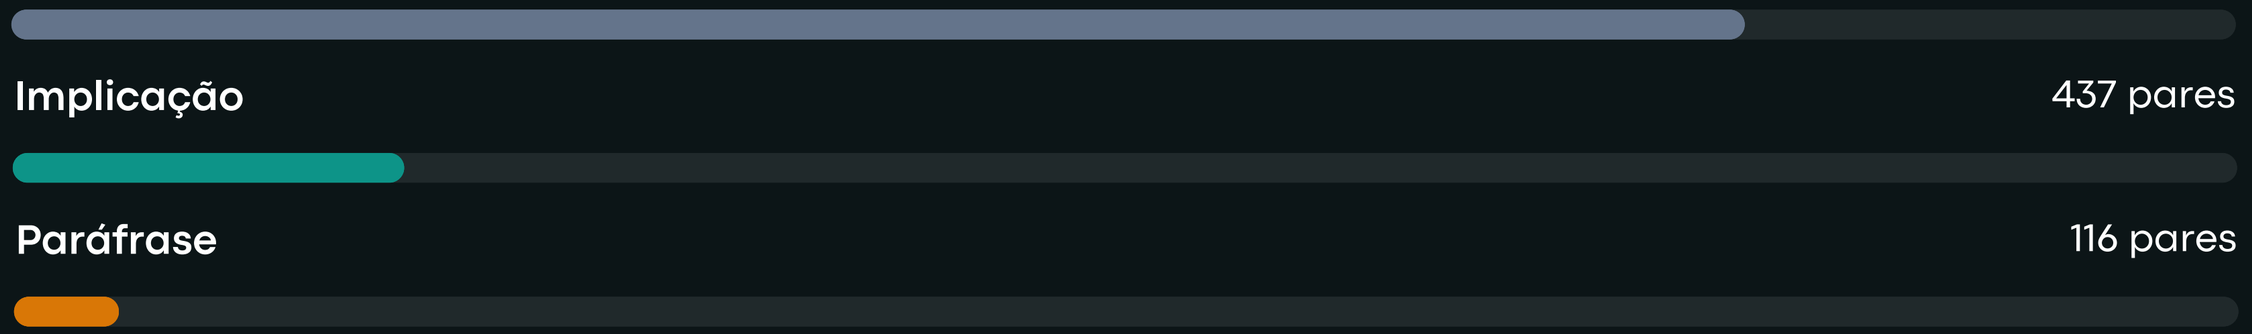
O desafio do desbalanceamento de classes

A maioria dos exemplos pertence à classe NONE

Sem implicação 1.947 pares

Implicação 437 pares

Paráfrase 116 pares



A classe “Sem implicação” é majoritária, enquanto “Paráfrase” é minoritária.

Por que isso importa?
Um classificador pode favorecer a classe mais frequente e ter dificuldade para reconhecer as classes menores.

Estratégias preparadas

Pesos de classe
Aumentam a importância dos erros cometidos em classes minoritárias durante o treinamento.

Oversampling
Aumenta a quantidade de exemplos minoritários no treino, por exemplo, duplicando amostras.

Questão 2: conhecendo o corpus

Dimensão e organização dos dados

5.000
Pares de frases

3
Classes

130.184
Tokens no corpus processado

14.497
Formas distintas no vocabulário

Divisão dos dados



Treino (usado para aprender padrões)

2.500 pares (50%)

Validação (ajuda a comparar configurações)

500 pares (10%)

Teste (Reservado para a avaliação final)

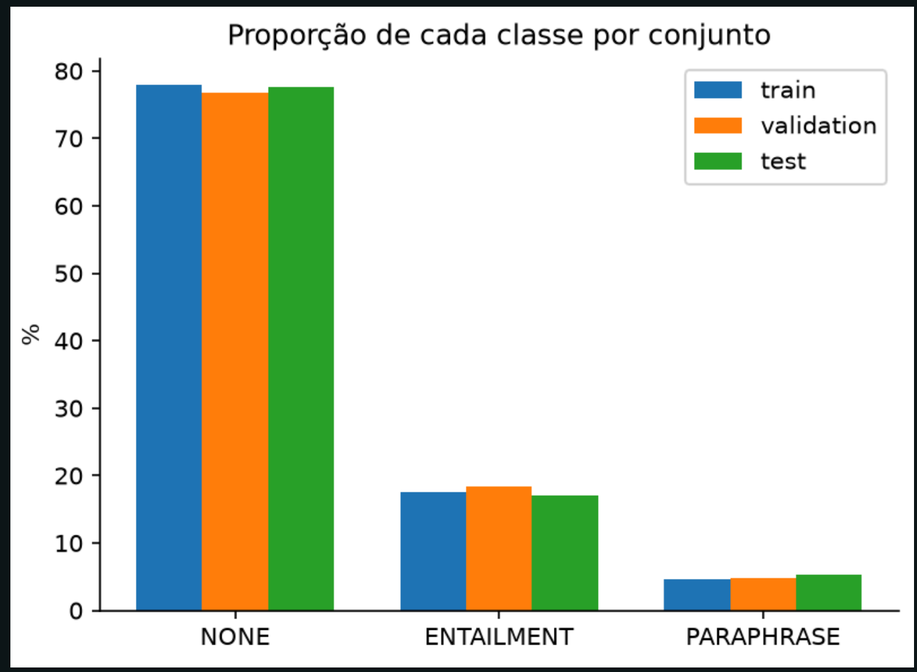
2.000 pares (40%)

Distribuição das classes nos três conjuntos

O desbalanceamento também aparece na validação e no teste

Proporção de cada classe em cada conjunto

Classe	Treino	Validação	Teste
NONE	77,9%	76,8%	77,6%
ENTAILMENT	17,5%	18,4%	17,0%
PARAPHRASE	4,6%	4,8%	5,3%



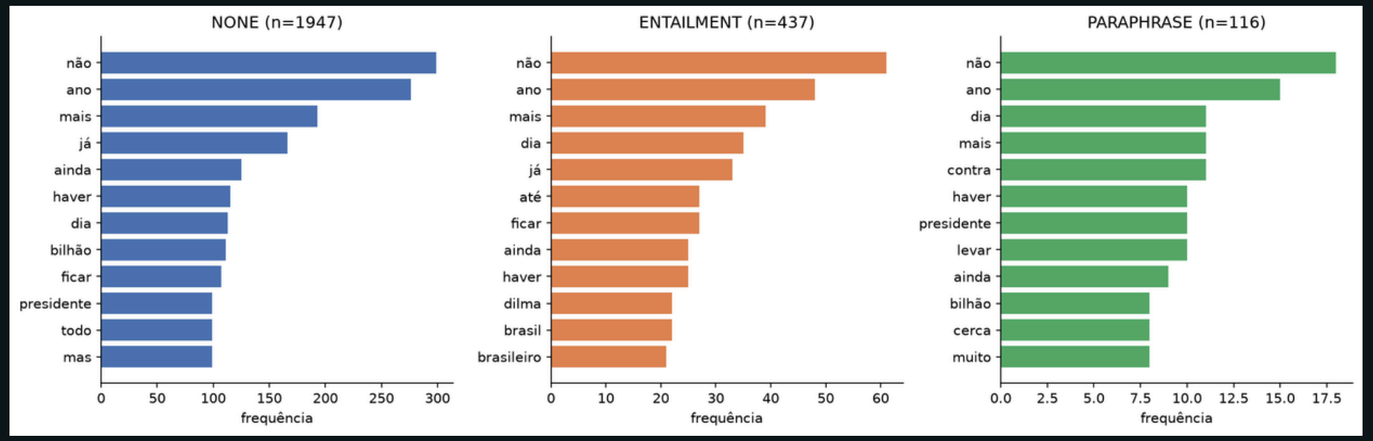
As proporções são semelhantes nos três conjuntos, mas a classe PARAPHRASE continua sendo minoritária.

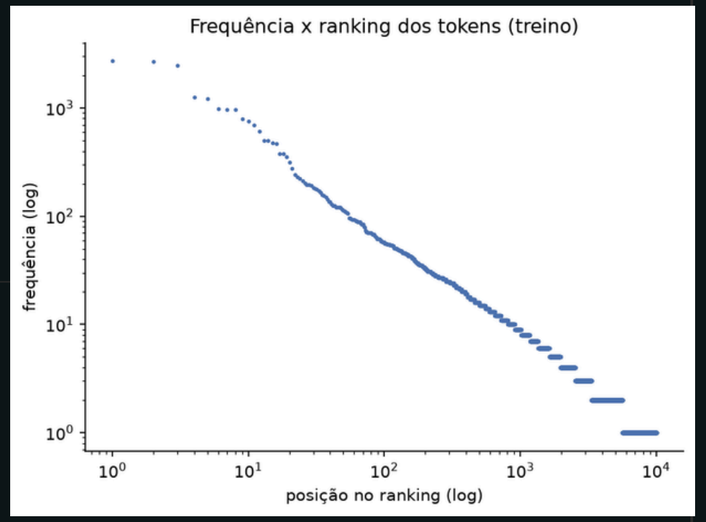
Por isso, precisamos avaliar se os classificadores conseguem reconhecer as três classes, e não apenas acertar a maioria.

Frequência das palavras e lei de Zipf

Quais palavras aparecem mais no corpus?

Palavra	Ocorrências
não	378
ano	339
mais	243
já	203
ainda	159
dia	159





Muitas palavras são raras

10.029
Formas no vocabulário do treino

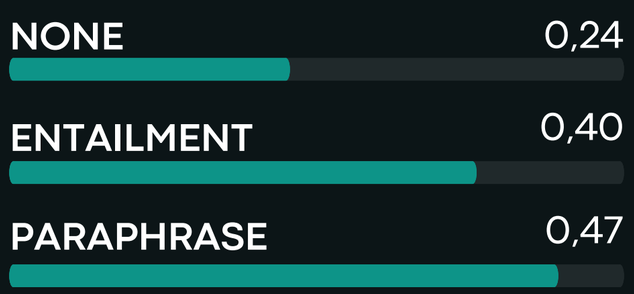
43,6%
Aparecem apenas uma vez

A distribuição de frequências apresenta o padrão geral conhecido como lei de Zipf: poucas palavras são muito frequentes e muitas palavras são raras.

Comparação entre as classes: semelhança lexical e negação

Duas pistas: sobreposição lexical e negação

1. Índice de Jaccard médio (mede a proporção de palavras compartilhadas por duas frases em relação ao total de palavras distintas presentes no par)



A média da classe PARAPHRASE foi a maior, com 0,47. Isso é coerente com a expectativa de que duas frases que expressam a mesma ideia frequentemente compartilhem palavras.

A classe ENTAILMENT teve média 0,40, menor que PARAPHRASE.

Já NONE apresentou média 0,24, a menor das três. Isso indica que, em média, os pares dessa classe compartilham uma proporção menor de palavras.

2. Negação presente em apenas uma frase

Classe	Pares
NONE	14,5%
ENTAILMENT	5,0%
PARAPHRASE	5,1%

A negação assimétrica foi mais frequente na classe NONE. Isso sugere que a presença de negação em apenas uma frase pode ajudar a identificar pares com relações diferentes.

Representação numérica dos textos e aplicações não supervisionadas

Transformação dos textos

- Utilizamos o TF-IDF para transformar as palavras em números e permitir que o computador compare os textos.
- Foram utilizados 3.367 termos. Como cada frase contém apenas parte dessas palavras, somente 0,28% dos valores da matriz eram diferentes de zero.
- Também calculamos 13 características dos pares, como palavras em comum, tamanho das frases, presença de negação e números.

Análises realizadas

- Redução de dimensionalidade: resumimos os dados para facilitar sua análise e visualização.
- K-Means: agrupamos pares com características semelhantes. Entre os testes, 7 grupos apresentaram o melhor resultado (silhouette de 0,214).
- NMF: buscamos identificar conjuntos de palavras relacionadas a assuntos semelhantes.
- Similaridade lexical: verificamos o quanto as duas frases compartilham palavras.
- Isolation Forest: identificamos 50 pares que apresentavam características diferentes das mais comuns no conjunto.

Resultado geral: essas análises ajudaram a explorar os dados e encontrar padrões, sem garantir que os grupos encontrados correspondessem às classes originais do ASSIN.

Próxima etapa
Treinar e comparar classificadores supervisionados, avaliando o desempenho nas três classes.

Questão 3: como o computador lê um texto?

CountVectorizer

Conta quantas vezes cada palavra do vocabulário aparece no par. É o chamado Bag-of-Words (saco de palavras).

TF-IDF

Também parte da contagem, mas reduz o peso das palavras comuns e destaca as raras, que ajudam mais a diferenciar os pares.

Mesma configuração nos dois vetorizadores (comparação justa)

- Texto de entrada: lemas sem stopwords da premissa e da hipótese, juntas (negações preservadas)
- Só entram palavras que aparecem em pelo menos 2 pares do treino (min_df = 2)
- N-gramas testados: palavras soltas (1-1) e palavras soltas mais pares vizinhos (1-2)
- Vocabulário ajustado somente no treino.

Por que criamos atributos de relação?

O problema

- Contar palavras não compara as duas frases
- A Q2 mostrou: o que separa as classes é a relação entre elas (Jaccard 0,24 / 0,40 / 0,47; negação só em uma frase: 14,5% em NONE contra cerca de 5%)
- Solução: 11 atributos numéricos de relação, calculados só do texto
- Não usamos o relatedness_score (vazamento)

Atributo	Significado
jaccard	Fração de palavras em comum entre as frases
h_em_p	Quanto da hipótese aparece na premissa
p_em_h	Quanto da premissa aparece na hipótese
n_lemas_p	Nº de palavras de conteúdo da premissa
n_lemas_h	Nº de palavras de conteúdo da hipótese
dif_tamanho	Tamanho da premissa menos o da hipótese
neg_p	1 se a premissa tem negação
neg_h	1 se a hipótese tem negação
neg_assimetrica	1 se só uma das frases tem negação
numeros_iguais	1 se os números das duas frases são os mesmos
numeros_novos_h	Nº de números da hipótese ausentes na premissa

Quais modelos e como tratamos o desbalanceamento?

Modelo	Ideia em uma frase
Naive Bayes	Probabilidade de cada classe a partir das palavras, assumindo que são independentes
Regressão Logística	Soma ponderada das features, convertida em probabilidade
SVM linear	Fronteira que separa as classes com a maior folga possível
MLP	Rede neural pequena (1 camada de 64 neurônios)

Desbalanceamento: 77,9 / 17,5 / 4,6%

- Sem tratamento (referência)
- Pesos de classe: 0,428 / 1,907 / 7,184 (errar PARAPHRASE pesa 17 vezes mais que errar NONE)
- Oversampling: classes pequenas repetidas até 1947 exemplos
- Nunca combinados; só no treino

Como escolhemos sem trapacear?

212

configurações treinadas (modelo, vetorizador, n-grama, atributos de relação e hiperparâmetros)

500

pares de validação servem para escolher a melhor configuração de cada modelo

1×

o teste (2000 pares) é usado uma única vez, na Questão 4

Métrica principal: F1 macro

- Média do F1 das três classes, com o mesmo peso para cada uma
- A acurácia engana: prever sempre NONE dá 0,768 de acurácia na validação, mas só 0,290 de F1 macro
- Todo modelo útil precisa vencer essa referência

O que a validação revelou?

Modelo	Melhor configuração	F1 macro	F1 PARAPHRASE
Naive Bayes	Count, 1-2, sem relação, nenhuma	0,407	0,125
Regressão Logística	TF-IDF, 1-1, relação, pesos	0,669	0,548
SVM linear	TF-IDF, 1-1, relação, pesos	0,681	0,604
MLP	TF-IDF, 1-2, relação, oversampling	0,656	0,571

0,40 → 0,67

F1 macro da Regressão Logística sem e com atributos de relação

0,22 → 0,60

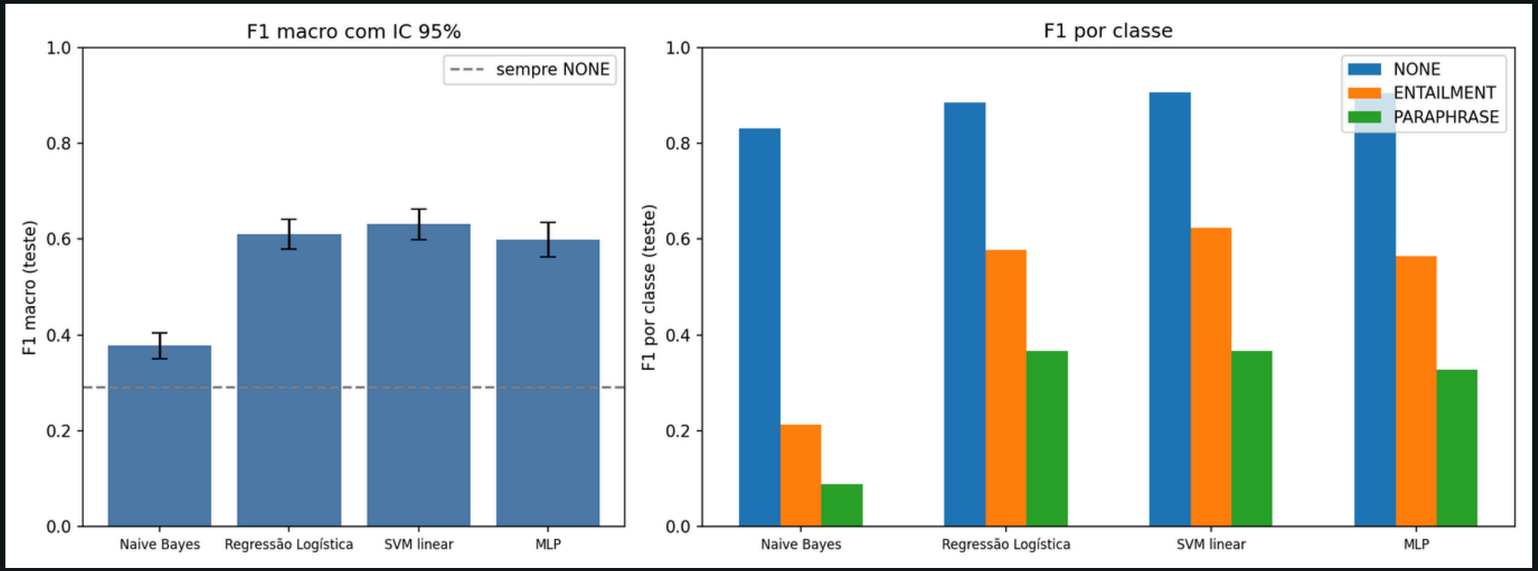
F1 de PARAPHRASE no SVM, sem tratamento e com pesos de classe

+0,02

vantagem média do TF-IDF sobre o Count, na comparação pareada

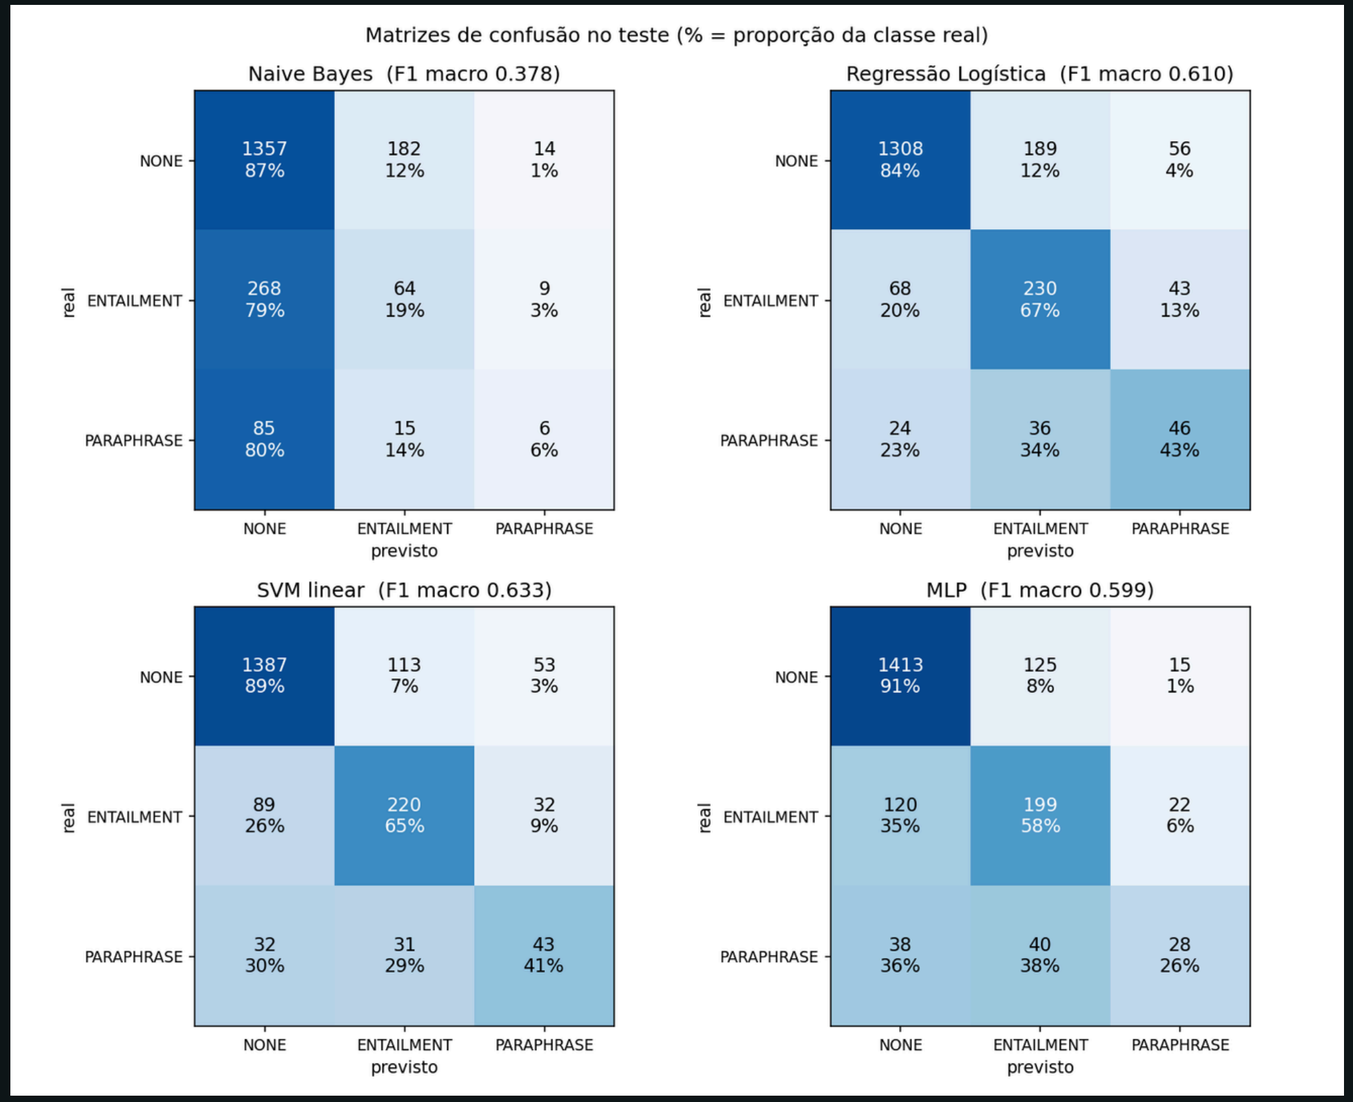
Questão 4: como cada modelo foi no teste?

Modelo	Acurácia	Precision	Recall	F1 macro	IC 95% do F1	F1 valid.
Sempre NONE (referência)	0,776	0,259	0,333	0,291	[0,287; 0,295]	--
Naive Bayes	0,714	0,415	0,373	0,378	[0,350; 0,405]	0,407
Regressão Logística	0,792	0,586	0,650	0,610	[0,579; 0,642]	0,669
SVM linear	0,825	0,620	0,648	0,633	[0,598; 0,664]	0,681
MLP	0,820	0,626	0,586	0,599	[0,563; 0,635]	0,656



- SVM: maior F1 macro, mas os intervalos de SVM, Regressão e MLP se sobrepõem
- Naive Bayes é claramente pior
- Acurácia engana: +5 pontos sobre a referência, mas F1 macro mais que dobra

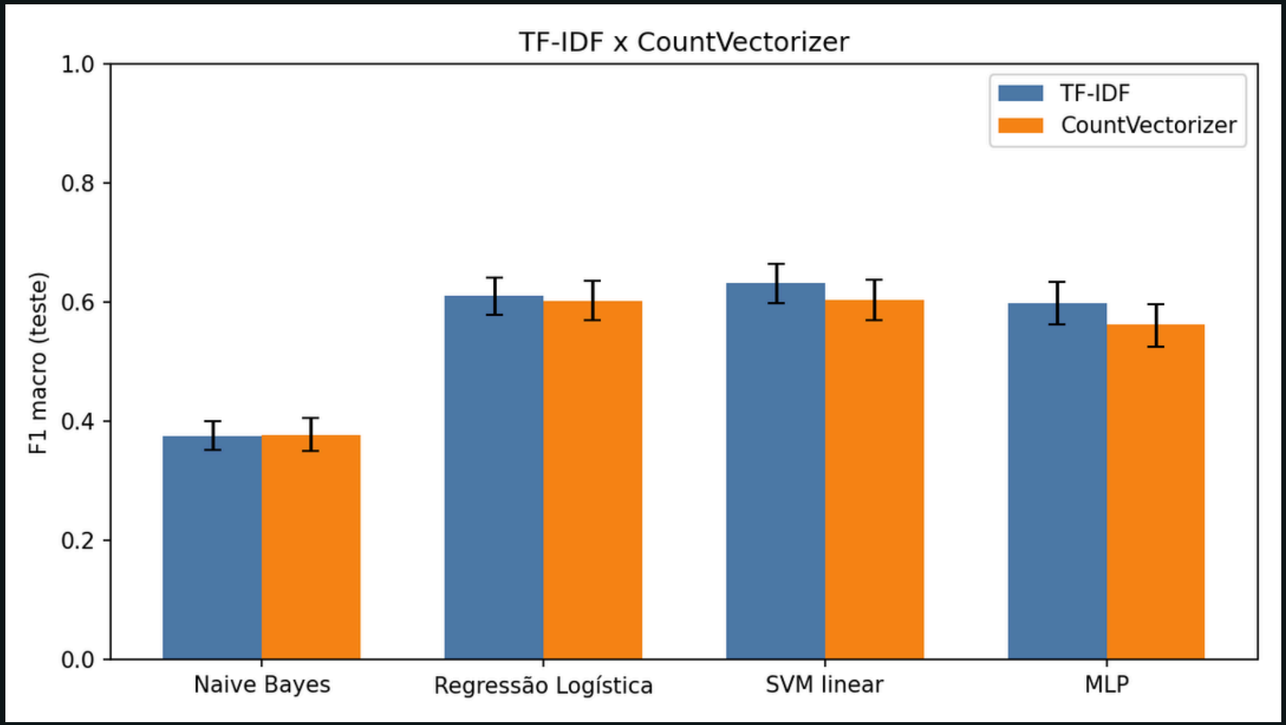
Onde os modelos acertam e erram?



F1 por classe	NONE	ENTAILMENT	PARAPHRASE
Naive Bayes	0,832	0,213	0,089
Reg. Logística	0,886	0,578	0,367
SVM linear	0,906	0,624	0,368
MLP	0,905	0,565	0,327

- PARAPHRASE é a classe mais difícil (F1 máximo de 0,37)
- No SVM: 43 de 106 paráfrases acertadas; 32 viram NONE e 31 viram ENTAILMENT
- ENTAILMENT e PARAPHRASE se confundem entre si
- 53 pares NONE previstos como PARAPHRASE reduzem a precision

TF-IDF ou CountVectorizer?



Modelo	Δ F1	IC 95% de Δ
Naive Bayes	−0,002	[−0,031; 0,027]
Reg. Logística	+0,008	[−0,015; 0,031]
SVM linear	+0,029	[−0,004; 0,060]
MLP	+0,037	[0,008; 0,067]

Δ = F1 do TF-IDF menos F1 do Count

- Só no MLP o intervalo exclui o zero
- No SVM, está perto do limite
- Cada vetorizador usa sua melhor configuração na validação; na comparação pareada da Q3, TF-IDF ganhou cerca de +0,02

Por que o SVM erra?

47%

dos 350 erros são pares NONE classificados como relacionados

0,96 → 0,62

acurácia nos pares de baixa para alta sobreposição de palavras

59%

das paráfrases foram classificadas incorretamente (63 de 106)

O que isso sugere (hipóteses)

- O modelo usa a sobreposição de palavras como atalho: nesse grupo 47% são NONE, mas ele só prevê NONE em 33%
- Paráfrases com palavras diferentes (siglas, sinônimos) escapam da contagem: 'PF' e 'Polícia Federal'
- Baseado em poucos exemplos lidos.

Discussão crítica e limitações

Por que o SVM teve o maior F1 macro

- Atributos de relação: F1 macro de cerca de 0,40 para 0,67 na validação
- Tratamento do desbalanceamento, essencial para PARAPHRASE
- Modelo linear regularizado funciona bem em dados esparsos e pouco numerosos; o MLP, com mais parâmetros, não o superou
- Naive Bayes ignora a relação entre as frases: ficou perto da referência
- Queda de 0,03 a 0,06 da validação para o teste: validação um pouco otimista

Limitações

- Bag-of-words ignora a ordem e não compara as frases
- Só 116 / 24 / 106 paráfrases (treino / validação / teste)
- 212 configurações avaliadas em 500 pares
- Sem validação cruzada e sem comparação estatística pareada entre os modelos
- Rótulos com componente subjetivo; corpus só de notícias

Questão 5: o que dificultou e o que melhorar?

1. O que mais dificultou

- Desbalanceamento de 16,8 para 1: a acurácia engana e PARAPHRASE tem poucos exemplos
- Corpus pequeno (2500 pares de treino) e vocabulário esparso
- A tarefa depende da relação entre duas frases, não do assunto
- Evitar vazamento: vetorizador só no treino, sem relatedness_score, teste usado uma vez

2. Melhorias possíveis

- Dataset: mais exemplos de PARAPHRASE, revisão de rótulos duvidosos, outros domínios;
- Pré-processamento: trechos em inglês, revisar palavras protegidas (numerais e ordinais);
- Modelos: validação cruzada, grade de hiperparâmetros mais ampla (o SVM escolheu o menor C), usar mais atributos de relação.

Aplicações reais e segunda versão

3. Aplicações reais

- Checagem de fatos: o texto sustenta a afirmação?
- Detecção de perguntas ou notícias duplicadas
- Avaliação automática de resumos e busca semântica
- Antes: medir em outros domínios e monitorar as classes raras

4. Segunda versão

- Aumento de dados para PARAPHRASE e perda ponderada
- Calibração das probabilidades

Síntese

O melhor modelo foi o SVM linear (TF-IDF, atributos de relação, pesos de classe): F1 macro de 0,633 no teste (IC 0,598 a 0,664), contra 0,291 da referência. A principal limitação é a classe PARAPHRASE (F1 de 0,368): contar palavras não capta sinônimos nem o significado.

OBRIGADO PELA ATENÇÃO!